

Cancellation Prediction Model— Random Forest

v1.2

Nguồn dữ liệu: hotel_bookings_v5.csv

Phạm vi: 82.811 booking | Tỷ lệ hủy tổng thể: **28,12%** (~23.284 booking bị hủy)

Notebook tham chiếu: Cancellation_Prediction_Model_v1_2.ipynb

Thuật toán: RandomForestClassifier (scikit-learn) + giải thích SHAP (TreeExplainer)

Ngưỡng phân loại: 0,35 ($P(\text{hủy}) \geq 0,35 \rightarrow \text{dự đoán Hủy}$)

1. Mục tiêu & khác biệt so với v1.1

v1.2 kế thừa v1.1 và bổ sung **feature engineering** theo 4 nhóm biến, đồng thời dùng **SHAP** để giải thích đóng góp của từng biến mới vào quyết định dự đoán.

Tiêu chí	v1.1	v1.2
Số feature gốc	9 (6 phân loại + 3 số)	16 (6 phân loại + 10 số)
Feature engineering	Không	9 biến engineered (4 nhóm)
Biến lịch sử	previous_cancellations (thô)	'history_cancel_rate' (tỷ lệ)
Giải thích mô hình	Feature importance (Gini)	Gini + SHAP (local & global)
Ngưỡng	0,35	0,35 (giữ nguyên)
ROC-AUC (test)	0,831	0,840
Recall — Hủy @ 0,35	0,94	0,94

Cải thiện chính: ROC-AUC tăng **+0,009** (~+1,1%) so v1.1; 4 biến engineered lọt **top 20** Gini importance; SHAP xác nhận **lead_time_per_night** là biến engineered đóng góp mạnh nhất.

2. Thiết kế mô hình

2.1 Feature engineering (4 nhóm)

Nhóm 1 — Mức độ cam kết tài chính (Financial Commitment)

Biến	Công thức	Ghi chú
<code>total_guests</code>	<code>adults + children + babies</code>	Clip tối thiểu = 1
<code>price_per_person</code>	<code>adr / total_guests</code>	Giá trên mỗi khách
<code>is_family</code>	1 nếu <code>children > 0</code> hoặc <code>babies > 0</code>	Nhóm gia đình

Nhóm 2 — Cấu trúc chuyến đi (Trip Structure)

Biến	Công thức	Ghi chú
<code>total_nights</code>	<code>stays_in_weekend_nights + stays_in_week_nights</code>	Tổng đêm lưu trú
<code>lead_time_per_night</code>	<code>lead_time / total_nights</code>	Clip mẫu số ≥ 1

Nhóm 3 — Lịch sử và uy tín (Trust & History)

Biến	Công thức	Ghi chú
history_cancellation_rate	$\text{previous_cancellations} / (\text{previous_cancellations} + \text{previous_bookings_not_cancelled})$	= 0 nếu chưa có lịch sử

Nhóm 4 — Lịch & mùa (Calendar & Seasonality)

Biến	Công thức	Ghi chú
is_weekend_only	1 nếu weekend_nights > 0 và week_nights == 0	Chỉ ở cuối tuần
arrival_month_mapped	Tháng đến → số 1–12 (Jan→1 ... Dec→12)	Mùa vụ

2.2 Feature đưa vào mô hình (16 biến)

Biến	Kiểu	Xử lý
deposit_type, market_segment, country, distribution_channel, customer_type, hotel	Phân loại	One-Hot Encoding
lead_time, total_of_special_requests	Số (v1.1)	Passthrough
8 biến engineered ở trên	Số	Passthrough

ColumnTransformer: nhánh cat (One-Hot, min_frequency=5) + nhánh num (passthrough). Sau encoding: **139 cột** đầu vào Random Forest.

Hyperparameter RF (giữ v1.1): `n_estimators=300, max_depth=12, min_samples_leaf=20, class_weight='balanced'`.

2.3 Chống data leakage

1. Không nạp `reservation_status`, `revenue`, `Occupancy_Rate`, `RevPAR`, ...
2. Feature engineering chỉ dùng thông tin **có tại thời điểm đặt phòng** (`adr`, `lead_time`, lịch sử khách, ...).
3. `train_test_split` **trước** mọi bước fit encoder.
4. `OneHotEncoder` chỉ fit trên tập train (qua `Pipeline`).

Lưu ý: `history_cancel_rate` tổng hợp lịch sử quá khứ — hợp lệ vì biết khi khách đặt; không phải leakage của booking hiện tại.

2.4 Ngưỡng 0,35

```
y_pred = 1 nếu P(hủy) >= 0.35
```

Giữ ngưỡng v1.1 để so sánh công bằng: ưu tiên **Recall** (không bỏ sót booking sẽ hủy), chấp nhận tăng False Positive.

3. Kết quả đánh giá (tập test — 16.563 booking)

3.1 Chỉ số tổng hợp @ ngưỡng 0,35

Chỉ số	Giá trị	Diễn giải
ROC-AUC (test)	0,840	Tốt — cải thiện +0,009 so v1.1
CV ROC-AUC (5-fold)	0,838 ± 0,004	Ổn định, generalize tốt

Chỉ số	Giá trị	Diễn giải
Accuracy	0,62	Không dùng làm metric chính (class lệch)
Precision — Hủy	0,42	~42% dự đoán hủy là đúng
Recall — Hủy	0,94	Bắt ~94% booking thực sự hủy
F1 — Hủy	0,58	@ 0,35
Precision — Không hủy	0,95	Rất cao khi dự đoán không hủy
Recall — Không hủy	0,49	~51% booking không hủy bị gán nhầm “hủy”

3.2 So sánh ngưỡng 0,35 vs 0,50 (cùng mô hình v1.2)

Metric (class Hủy)	@ 0,50	@ 0,35
F1	0,613	0,581
Recall	0,83	0,94
FN (bỏ sót hủy)	~812	~289

Kết luận ngưỡng: 0,35 giảm FN từ ~812 xuống **289** (−64%) — phù hợp chiến lược inventory protection; 0,50 tốt hơn nếu ưu tiên F1 / Precision.

3.3 Ma trận nhầm lẫn @ 0,35

	Dự đoán: Không hủy	Dự đoán: Hủy
Thực tế: Không hủy	TN = 5.893	FP = 6.013
Thực tế: Hủy	FN = 289	TP = 4.368

3.4 Phân phối xác suất dự đoán (test)

Nhãn thực tế	n	Mean P(hủy)	Median P(hủy)	Std
Không hủy	11.906	0,384	0,354	0,173
Hủy	4.657	0,612	0,627	0,143

Hai phân phối tách lớp rõ hơn v1.1 (AUC cao hơn). Ngưỡng 0,35 nằm trong vùng overlap → tăng Recall, kéo theo nhiều FP.

4. Feature importance (Gini)

4.1 Top 20 feature (sau tiền xử lý)

Hạng	Feature	Importance	Biến gốc / nhóm
1	lead_time	0,141	lead_time
2	country_PRT	0,113	country
3	market_segment_Online TA	0,111	market_segment
4	`lead_time_per_night`	0,108	Trip Structure
5	total_of_special_requests	0,085	total_of_special_requests
6	market_segment_Offline TA/TO	0,056	market_segment
7	customer_type_Transient	0,042	customer_type

Hạng	Feature	Importance	Biến gốc / nhóm
8	`history_cancel_rate`	0,033	Trust & History
9	distribution_channel_TA/TO	0,029	distribution_channel
10	customer_type_Transient-Party	0,028	customer_type
11	`price_per_person`	0,028	Financial Commitment
12	deposit_type_Non Refund	0,028	deposit_type
13	`total_nights`	0,027	Trip Structure
14	distribution_channel_Direct	0,020	distribution_channel
15	deposit_type_No Deposit	0,019	deposit_type
16	market_segment_Direct	0,017	market_segment
17	country_GBR	0,016	country
18	`total_guests`	0,013	Financial Commitment
19	country_FRA	0,010	country
20	`arrival_month_mapped`	0,008	Calendar & Seasonality

Nhận xét: 4 biến engineered trong top 20; lead_time_per_night (#4) gần sát lead_time (#1) — chuẩn hóa lead time theo độ dài chuyến đi mang tín hiệu dự báo mạnh.

4.2 Gom nhóm theo biến gốc (tổng Gini importance)

Hạng	Biến / nhóm	Tổng importance	Đánh giá
1	market_segment	0,195	Kênh OTA vẫn quan trọng
2	country	0,164	Thị trường nguồn (PRT)
3	lead_time	0,141	Đặt trước xa → rủi ro cao
4	`lead_time_per_night`	0,108	Biến engineered mạnh nhất
5	total_of_special_requests	0,085	Cam kết / nhu cầu cụ thể
6	customer_type	0,077	Transient rủi ro hơn
7	distribution_channel	0,054	TA/TO vs Direct
8	deposit_type	0,047	Chính sách cọc
9	`history_cancel_rate`	0,033	Lịch sử hủy — tín hiệu phụ
10	`price_per_person`	0,028	Cam kết tài chính
11	`total_nights`	0,027	Cấu trúc chuyến đi
12	hotel	0,015	City vs Resort
13	`total_guests`	0,013	Quy mô nhóm khách
14	`arrival_month_mapped`	0,008	Mùa vụ — yếu hơn
15	`is_family`	0,003	Gia đình — yếu
16	`is_weekend_only`	0,002	Cuối tuần — yếu nhất

5. Giải thích SHAP — Biến engineered

5.1 Phương pháp


Thành phần	Cài đặt
Thư viện	<code>shap</code> — <code>TreeExplainer</code>
Mô hình giải thích	<code>RandomForestClassifier</code> sau <code>ColumnTransformer</code>
Dữ liệu	Mẫu 2.000 booking ngẫu nhiên từ tập test (<code>random_state=42</code>)
Class giải thích	Hủy (class 1) — SHAP đo đóng góp vào <code>P</code> (hủy)

Cách đọc SHAP:

- **SHAP > 0** → đẩy xác suất hủy **tăng** (nguy cơ cao hơn)
- **SHAP < 0** → đẩy xác suất hủy **giảm** (nguy cơ thấp hơn)
- **|SHAP| lớn** → feature đóng góp mạnh vào quyết định **cho booking cụ thể**

Khác với Gini importance (trung bình toàn cục, không có dấu), SHAP cho biết **hướng** và **mức độ** tác động trên từng quan sát.


5.2 Mean |SHAP| — Xếp hạng biến engineered



Hạng	Biến	Mean SHAP	Mean SHAP	Nhóm	Diễn giải
1	'lead_time_per_night'	0,032	−0,005	Trip Structure	Đóng góp lớn nhất; trung bình hơi kéo P(hủy) xuống
2	price_per_person	0,011	−0,002	Financial Commitment	Giá/người cao → thường giảm rủi ro hủy
3	total_nights	0,010	−0,001	Trip Structure	Số đêm dài hơn → xu hướng giảm rủi ro
4	history_cancel_rate	0,006	−0,001	Trust & History	Lịch sử hủy cao → SHAP dương mạnh trên từng case
5	total_guests	0,004	−0,000	Financial Commitment	Nhiều khách → tác động nhỏ

Hạng	Biến	Mean SHAP	Mean SHAP	Nhóm	Diễn giải
6	arrival_month_mapped	0,003	−0,000	Calendar	Mùa vụ — tác động yếu
7	is_family	0,002	−0,000	Financial Commitment	Gia đình — tác động yếu
8	is_weekend_only	0,001	−0,000	Calendar	Cuối tuần — yếu nhất

5.3 Tổng hợp theo nhóm feature engineering




Nhóm	Tổng mean SHAP	Mean SHAP	Đánh giá
Trip Structure	0,042	−0,006	Nhóm engineered quan trọng nhất — chủ yếu nhờ <code>lead_time_per_night</code>

Nhóm	Tổng mean SHAP	Mean SHAP	Đánh giá
Financial Commitment	0,017	-0,003	price_per_person là trụ chính
Trust & History	0,006	-0,001	Một biến nhưng có giá trị khi lịch sử hủy > 0
Calendar & Seasonality	0,004	-0,000	Tín hiệu phụ so với lead time / segment


5.4 Diễn giải theo từng biến (SHAP + Gini)

lead_time_per_night (Trip Structure)




- **Gini #4 toàn mô hình | SHAP #1 trong nhóm engineered**
- Chuẩn hóa lead_time theo số đêm giúp tách booking “đặt sớm nhưng ở ngắn” vs “đặt sớm và ở dài”.
- Trên trung bình mẫu SHAP hơi âm: lead time/đêm **thấp** (đặt gấp, ở nhiều đêm) thường gần SHAP dương → tăng P(hủy); **cao** → giảm P(hủy).
- **Hành động:** Kết hợp rule lead_time_per_night cao với segment OTA để ưu tiên xác nhận / cọc.

price_per_person (Financial Commitment)



- **Gini #11 | SHAP #2 engineered**
- Giá trên mỗi khách phản ánh mức cam kết tài chính tương đối; SHAP âm trung bình → giá/người cao hơn thường **giảm** xác suất hủy.
- **Hành động:** Booking ADR thấp/khách + lead time dài → ưu tiên can thiệp (upsell, cọc).

total_nights (Trip Structure)



- **Gini #13 | SHAP #3 engineered**
- Chuyển dài hơn → xu hướng cam kết cao hơn (SHAP âm trung bình).
- Bổ sung cho `lead_time`: không chỉ “đặt trước bao lâu” mà “ở bao lâu”.

history_cancel_rate (Trust & History)

- **Gini #8 | SHAP #4 engineered**
- Thay `previous_cancellations` thô bằng **tỷ lệ** giúp mô hình so sánh công bằng giữa khách ít/nhiều lịch sử.
- Khi `history_cancel_rate > 0` (đặc biệt ≈ 1), SHAP **đương mạnh** → đẩy P(hủy) lên rõ rệt trên từng booking.
- **Hành động**: Flag riêng khách có tỷ lệ hủy quá khứ $\geq 50\%$.

total_guests, is_family (Financial Commitment)

- Tác động SHAP nhỏ; `is_family` yếu nhất trong nhóm Financial.
- Gia đình (có trẻ) không tạo tín hiệu hủy mạnh ở mức tổng thể — có thể do tương quan với `segment` / `lead time`.

arrival_month_mapped, is_weekend_only (Calendar)

- SHAP và Gini đều thấp nhất trong các biến engineered.
- Mùa vụ và “chỉ cuối tuần” có tín hiệu nhưng **bị lu mờ** bởi `market_segment`, `lead_time`, `country`.


5.5 Biểu đồ SHAP trong notebook

Biểu đồ	Nội dung
Bar SHAP theo biến & nhóm	So sánh độ lớn đóng góp trung bình
Beeswarm	Phân bố SHAP theo giá trị feature (màu = cao/thấp)
Dependence (top 3)	Quan hệ phi tuyến: <code>lead_time_per_night</code> , <code>price_per_person</code> , <code>total_nights</code>

Biểu đồ	Nội dung
Waterfall	Giải thích từng booking nguy cơ cao / thấp (toàn feature)
Bar engineered	Chỉ 8 biến mới trong 2 ví dụ điển hình


6. Trực quan hóa & đánh giá biểu đồ

6.1 Confusion Matrix (@ 0,35)





FN = 289 (giảm so v1.1 ~273–289 tùy run), FP = 6.013. Chiến lược ngưỡng thấp — phù hợp **không bỏ sót hủy**, không phù hợp nếu mỗi cảnh báo tổn chi phí cao.

6.2 ROC Curve (AUC = 0,840)



Cải thiện so v1.1 (0,831). Mô hình xếp hạng rủi ro tốt; ngưỡng 0,35 là điểm cắt kinh doanh, không ảnh hưởng AUC.

6.3 Prediction Probability Distribution



Median P(hủy): Không hủy **0,35** · Hủy **0,63** — tách lớp tốt. Overlap vùng 0,25–0,55 vẫn tồn tại (bình thường với dữ liệu hành vi).

6.4 Feature Importance vs SHAP

Góc nhìn	Gini importance	SHAP
Phạm vi	Toàn cục, không dấu	Local + trung bình có dấu
Biến engineered nổi bật	lead_time_per_night, history_cancel_rate, price_per_person	Cùng thứ tự; SHAP bổ sung hướng tác động
Khuyến nghị	Chọn feature, ranking	Giải thích quyết định, audit từng booking

7. Kết luận tổng thể

Điểm mạnh v1.2

- 1. **ROC-AUC 0,840** — cải thiện so v1.1, sẵn sàng pilot scoring nội bộ.
- 2. **Feature engineering có giá trị:** lead_time_per_night vào top 4 toàn mô hình; 4/8 biến engineered trong top 20 Gini.
- 3. **SHAP** xác nhận và bổ sung hướng tác động — đặc biệt hữu ích cho history_cancel_rate và price_per_person ở mức từng booking.
- 4. Ngưỡng **0,35** giữ **Recall 94%**, FN ≈ 289.

Hạn chế & rủi ro

- 1. **Precision thấp** (~42%) @ 0,35 — nhiều booking không hủy bị flag.
- 2. Biến Calendar (is_weekend_only, arrival_month_mapped) **đóng góp yếu** — có thể thử encoding mùa (Spring/Summer/...) hoặc bỏ để giảm nhiễu.
- 3. SHAP trên Random Forest + One-Hot **tốn thời tính toán** — production nên cache explainer hoặc giảm mẫu.
- 4. Gini / SHAP **không phải nhân quả** — cần A/B trước khi đổi chính sách giá hoặc cọc.

Khuyến nghị hành động

Ưu tiên	Hành động	Feature / SHAP liên quan
1	Rule kết hợp: Online TA + `lead_time_per_night` cao → xác nhận chặt	Trip Structure, segment
2	Flag khách `history_cancel_rate` > 0 (đặc biệt ≈ 1)	Trust & History
3	Booking `price_per_person` thấp + lead time dài → ưu tiên cọc / upsell	Financial Commitment
4	Pilot: <code>P (hủy) >= 0,35</code> + giải thích SHAP top-3 feature cho RM	Notebook mục 7
5	Thử v1.3: seasonal encoding, interaction (<code>lead_time_per_night × market_segment</code>)	Calendar, Trip

8. Tài liệu liên quan

Tài liệu	Nội dung
<code>Cancellation_Prediction_Model_v1_2.ipynb</code>	Notebook đầy đủ (huấn luyện + SHAP)
Cancellation Prediction Model v1.1.md	Phiên bản trước (9 feature)
Cancellation Prediction Model v1.md	Baseline phân loại
Hypothesis Testing - is_canceled.md	Kiểm định lead_time, deposit, segment
Correlation Analysis - is_canceled.md	Tier feature & leakage

