

EDA Stage 1: Cancellation Analysis

Nguồn dữ liệu: hotel_bookings_v4.csv

Phạm vi: 82.811 booking | Tổng hủy phòng: 28,12% (23.284 booking hủy)


Notebook tham chiếu: 02_eda_stage1_cancellation.ipynb

Mục tiêu phân tích

Giai đoạn EDA Stage 1 tập trung khám phá mối quan hệ giữa **lời hủy phòng (is_canceled)** và các yếu tố hành vi khách phòng: thời gian đặt trước (lead_time), loại tiền cọc (deposit_type), phân khúc thị trường (market_segment) và kênh phân phối (distribution_channel). Mục tiêu chính là **đánh giá ảnh hưởng** của từng chi tiêu phân tích, kèm insight có thể hành động được.

Nhóm 1 — Lead time (Biểu 1 → 5)

Biểu 1: Histogram số booking theo lead_time bin (tách theo is_canceled)



Mô tả: Grouped bar + stacked bar 100% — trục X = khoảng lead_time (0–30, 31–60, 61–90, 91–180, >180 ngày), trục Y = số lượng booking, tách màu theo Không hủy / Đã hủy.


Insight:

Lead time bin	Tổng booking	Đã hủy	Tỷ lệ hủy
0–30 ngày	33.039	5.559	16,8%
31–60 ngày	12.776	4.115	32,2%
61–90 ngày	8.967	2.978	33,2%
91–180 ngày	17.355	6.178	35,6%

>180 ngày	10.674	4.454	41,7%
-----------	--------	-------	-------

- Bin **0–30 ngày** chỉ **m ~39,9%** tổng booking và có volume không **h** lớn nh**t** (27.480 booking) — **â** là nhóm "an toàn" nh**ng** v**n** **óng** góp **23,9%** tổng s**ố** booking b**ị** **h**.
- Bin **91–180 ngày** có volume cao th**ai** (17.355) và **óng** góp **26,5%** tổng cancellation — r**ủ** ro t**h**p trung **kh**o**ng** **ít** tr**ở**c trung-dài h**n**.
- Stacked bar 100% cho th**ấy** t**h** l**à** ph**ần** "**ã** **h**" t**h**ng d**ẫn** r**õ** r**ệt** t**h** bin 0–30 sang >180, xác nh**an** lead_time dài h**n** → xác su**ất** **h** cao h**n**.

Bi**ê**u **■** 2: Histogram + KDE overlay (tr**ở**c Y kép)




Mô **t**: Histogram count theo lead_time liên t**h**c (tr**ở**c Y trái) k**ết** h**ợp** **■** KDE density (tr**ở**c Y ph**ải**), tách theo is_canceled.

Insight:

- Phân b**ộ** lead_time c**ủa** booking **không** **h** t**h**p trung m**ạnh** **■** vùng **0–100 ngày**, **■**nh density cao nh**t** quanh **30–60 ngày**.
- Booking **ã** **h** có phân b**ộ** d**ịch** sang ph**ải** (lead_time cao h**n**), **■**nh density n**h**m **■** kho**ng** **60–120 ngày** và v**n** còn **u**ôi dài **■** **>300 ngày**.
- Hai **■** KDE giao nhau **■** kho**ng** **~45–55 ngày**: d**ể** **■** ng**■**ng này booking không **h** chỉ **m** **u** th**■**; trên ng**■**ng này booking **h** tr**■** nên ph**ải** bi**ết** h**n** t**h**ng **■**.

Bi**ê**u **■** 3: Histogram theo bin + KDE liên t**h**c (2 subplot)

Phân bố lead_time theo is_canceled




Mô tả: Subplot trái = histogram rời rạc theo bin; subplot phải = KDE lead_time liên tục — cả hai tách theo trạng thái hủy.

Insight:

- Histogram theo bin làm rõ **biểu đồ nhô lên nhất** và **tỉ lệ hủy** xảy ra giữa bin **0–30** (16,8%) và **31–60** (32,2%) — **gần gấp đôi**.
- KDE liên tục bổ sung góc nhìn: booking hủy không chỉ "địch pha" mà còn **phân tán rộng hơn** (đỉnh lệch chuẩn cao hơn), phản ánh sự không chắc chắn cao hơn của các booking đặt xa ngày hơn.
- Kết hợp hai subplot: **lộ rõ hủy tăng bất biến** sau 30 ngày lead_time, không phải tăng tuyến tính mạnh mẽ.

Bíu 4: Boxplot + Violin plot (lead_time theo is_canceled)

Phân bố lead_time theo trạng thái hủy




Mô tả: Trạng thái hủy, trục X = trạng thái hủy, trục Y = lead_time (ngày).

Insight:

Trạng thái	Số booking	Mean	Median	Std
Không hủy (0)	59.527	68,2 ngày	37 ngày	79,1
Đã hủy (1)	23.284	104,9 ngày	79 ngày	91,3

- Median lead_time của booking hủy (79 ngày) cao hơn gấp ~2.1 lần so với booking không hủy (37 ngày).
- Violin plot cho thấy phân bố booking hủy dẹt và rộng hơn ở vùng 60–150 ngày, trong khi booking không hủy tập trung hơn quanh median thấp.
- Boxplot: IQR của nhóm hủy cao hơn đáng kể; cả hai nhóm đều có outlier (lead_time >400 ngày) nhưng nhóm hủy có nhiều outlier hơn ở vùng cao.

Biểu đồ 5: Line chart thể hiện hủy theo lead_time bin




Mô tả: Trục X = lead_time bin, trục Y = cancellation_rate (%).

Insight:

- Xu hướng **monotonic tăng** rõ rệt: 16,8% → 32,2% → 33,2% → 35,6% → 41,7%.
- Bước nhảy lớn nhất:** từ 0–30 lên 31–60 (+15,4 điểm %). Sau 60 ngày, tỷ lệ hủy tăng chậm hơn nhưng vẫn leo thang.
- Bin **>180 ngày** đạt **41,7%** — gần 2.5 lần bin 0–30 ngày.
- Hàm ý vận hành:** ngưỡng lead_time **30 ngày** là ranh giới quan trọng để phân loại rủi ro; booking >180 ngày cần chiến lược giá riêng (cố, xác nhận, pricing linh hoạt).

Nhóm 2 — Deposit type (Biểu 6 → 7)

Biểu 6: Bar chart thể hiện theo deposit_type




Mô t: Tr c X = deposit_type, tr c Y = cancellation_rate (%).

Insight:

Deposit type	Bookings	Cancellation rate
No Deposit	81.767 (98,7%)	27,3%
Non Refund	963 (1,2%)	95,0%
Refundable	81 (<0,1%)	28,4%

- **Non Refund** có t l h y c c cao (~95,0%) — g n nh m i booking lo i này u b h y trong dataset. Tuy nhiên volume r t nh (963 booking).
- **No Deposit** chi m g n toàn b dataset và kéo t l h y t ng th (~28,12%) — ây là nhóm c n u tiên can thi p vì scale l n.
- **Refundable** có sample quá nh (81) nên t l 28,4% c n di n gi i th n tr ng.

Bi u 7: Stacked bar 100% — Không h y vs ã h y theo deposit_type



Mô tả: Trục X = deposit_type, trục Y = tỷ lệ (%), stack theo is_canceled.


Insight:

Deposit type	Không hủy	Đã hủy
No Deposit	72,7%	27,3%
Non Refund	5,0%	95,0%
Refundable	71,6%	28,4%

- No Deposit:** có 4 booking thì gần 1 booking bị hủy — rủi ro khá cao khi không yêu cầu cọc.
- Non Refund:** gần như toàn bộ stack là "Đã hủy" — loại cọc này **không hiệu quả** trong việc giảm hủy (có thể do cách ghi nhận dữ liệu hoặc chính sách cọc khác với tên gọi).
- Refundable:** tỷ lệ hủy cao hơn No Deposit (~28,4% vs 27,3%), phù hợp vì khách có thể hủy và được hoàn cọc.
- Kết luận chính sách:** yêu cầu cọc (đặc biệt non-refundable) có liên quan mật thiết với hành vi hủy; cần xem xét mức ràng buộc cho segment rủi ro cao thay vì chỉ No Deposit chiếm 98,7% booking.

Nhóm 3 — Market segment (Biểu đồ 8 → 9)

Biểu đồ 8: Horizontal bar — tỷ lệ hủy theo market_segment (sắp giảm dần)



Mô t: Tr Y = market_segment, tr X = cancellation_rate (%).

**Insight (s p theo t l h y gi m d n):


Market segment	Bookings	Cancellation rate
Undefined	2	100,0%
Online TA	50.391	35,5%
Groups	3.690	31,2%
Aviation	220	19,1%
Offline TA/TO	12.860	15,1%
Direct	11.351	14,9%
Complementary	619	13,1%
Corporate	3.678	12,8%

*Undefined ch 2 booking — không có ý nghĩa thống kê.

- **Online TA** v a có volume l n nh t (~60,9% t ng booking) v a có t l h y cao nh t trong các segment chính — ây là i m nóng r i ro s 1.
- **Groups** c ng thu c nhóm r i ro cao (31,2%) dù volume nh h n.
- **Corporate** có t l h y th p nh t (12,8%) — segment n n nh, th ng là khách doanh nghi p có cam k t cao h n.

- **Direct** và **Offline TA/TO** có mức trung bình-thấp (~14,9–15,1%), thấp hơn đáng kể so với Online TA.

Biểu đồ 9: Dual-axis — Volume vs cancellation rate theo market_segment



Mô tả: Cột = số booking (sắp theo volume giảm dần), đường = cancellation_rate (%).


Insight:

- **Online TA** nổi bật: cột cao nhất (50.391) và đường cancellation cao (35,5%) — segment "vừa to vừa rủi ro".
- **Offline TA/TO** (12.860 booking, 15,1%) và **Direct** (11.351, 14,9%) có volume đáng kể nhưng tỷ lệ hủy thấp hơn nhiều — hiệu quả hơn về mặt giá booking.
- **Corporate** (3.678, 12,8%) và **Groups** (3.690, 31,2%) có volume tương đương nhưng tỷ lệ hủy chênh lệch gần 2.4 lần — cùng quy mô nhưng rủi ro rất khác nhau.
- **Aviation** (220, 19,1%) và **Complementary** (619, 13,1%) volume nhỏ, ít ảnh hưởng đến tổng cancellation nhưng vẫn hữu ích cho phân khúc chi nhánh.

Hàm ý: Ưu tiên can thiệp tại **Online TA** (impact lớn nhất lên tổng số booking hủy) thay vì tập trung vào các segment.

Nhóm 4 — Distribution channel (Biểu đồ 10 → 11)

Biểu đồ 10: Bar chart tỷ lệ hủy theo distribution_channel




Mô t: Trc X = distribution_channel (Direct, Corporate, TA/TO, GDS), trc Y = cancellation_rate (%).

Insight:

Distribution channel	Bookings	Cancellation rate
TA/TO	65.956 (79,6%)	31,5%
GDS	172 (0,2%)	19,8%
Direct	12.291 (14,8%)	15,1%
Corporate	4.387 (5,3%)	13,6%

- **TA/TO** chiếm ~80% booking và có t l h y cao nh t (31,5%) — kênh OTA/travel agent là ngu n chính c a cancellation.
- **Direct** (15,1%) và **Corporate** (13,6%) có t l h y th p h n ~50% so v i TA/TO — t tr c ti p ho c qua kênh doanh nghi p n nh h n.
- **GDS** có t l h 19,8% nh ng sample r t nh (172 booking) — c n th n tr ng khi k t lu n.
- Phân tích riêng theo channel ch a phân tách c s khác bi t bên trong t ng market segment — c n Bi u 11 làm rõ.

Bi u 11: Heatmap market_segment × distribution_channel



Mô tả: Trục X = distribution_channel, trục Y = market_segment, màu = cancellation_rate trung bình (%) của từng cặp (segment, channel). Ô trống (NaN) = không có booking cho cặp đó.

Ma trận cancellation rate (%)

Market segment ↓ / Channel →	Direct	Corporate	TA/TO	GDS	Undefined
Online TA	5,6	18,2	35,7	20,5	100,0
Groups	19,2	15,8	36,2	—	—
Offline TA/TO	21,4	7,9	15,1	18,2	—
Direct	15,2	10,8	3,7	0,0	50,0
Complementary	12,6	18,2	10,4	—	—
Corporate	10,6	13,0	11,8	—	—
Aviation	—	19,5	10,0	—	—
Undefined	—	—	—	—	100,0

*Sample rate nhỏ (≤ 2 booking) — chỉ mang tính tham khảo.

Ma trận volume (số booking)

Market segment ↓ / Channel →	Direct	Corporate	TA/TO	GDS	Undefined
Online TA	126	33	50.104	127	1
Groups	478	507	2.705	—	—
Offline TA/TO	14	76	12.726	44	—
Direct	11.057	74	217	1	2
Complementary	475	77	67	—	—
Corporate	141	3.410	127	—	—
Aviation	—	210	10	—	—
Undefined	—	—	—	—	2

Insight:

- **Tỷ lệ booking cao nhất (volume lớn):** Online TA × TA/TO — 50.104 booking, tỷ lệ booking 35,7% (~17.866 booking hủy được tính). Đây là ô "đỏ" lớn nhất trên heatmap, gợi ý thích phần lớn cancellation toàn hệ thống.
- **Tỷ lệ booking cao thứ hai:** Groups × TA/TO — 2.705 booking, tỷ lệ booking 36,2% (cao hơn cả Online TA × TA/TO về mặt tỷ lệ).
- **Tỷ lệ booking nhỏ nhất đáng kể:** Direct × TA/TO — chỉ 217 booking nhưng tỷ lệ booking 3,7% (thấp nhất trong các ô có n≥50). Segment Direct vượt qua kênh TA/TO hành xử rất khác so với Online TA qua cùng kênh.
- **Online TA × Direct** — 126 booking, tỷ lệ booking 5,6%: khi Online TA chuyển sang kênh Direct, tỷ lệ booking giảm mạnh so với TA/TO (35,7% → 5,6%).
- **Corporate segment** lớn nhất trên mọi kênh có dữ liệu: Corporate × Corporate (3.410 booking, 13,0%), Corporate × Direct (10,6%), Corporate × TA/TO (11,8%) — đều duy trì mức trung bình chung (28,12%).
- **Offline TA/TO × TA/TO** — 12.726 booking (volume lớn thứ hai) nhưng tỷ lệ booking chỉ 15,1%, thấp hơn nhiều so với Online TA × TA/TO dù cùng kênh TA/TO → **market segment quan trọng hơn channel** trong việc gợi ý thích hủy.
- **Groups × Direct** (478 booking, 19,2%) cao hơn Groups × Corporate (15,8%) — kênh Direct không luôn "an toàn" nếu segment vẫn rủi ro cao.
- **Aviation × TA/TO** (10 booking, 10,0%) và **Direct × GDS** (1 booking, 0%) — không đủ sample để kết luận.

Hàm ý chính từ heatmap:

- Tỷ lệ hủy không chỉ do kênh TA/TO mà do **sự giao thoa segment × channel** — cùng kênh TA/TO, Online TA (35,7%) và Offline TA/TO (15,1%) chênh lệch ~21 điểm phần trăm.
 - Cần thiết lập nên **target theo ô cell** (vd. Online TA + TA/TO + lead_time dài) thay vì penalize toàn bộ kênh TA/TO.
 - Feature interaction `market_segment × distribution_channel` là candidate mạnh cho mô hình predictive (Stage 2).
-

Tổng hợp insight xuyên suốt (Biểu 1–11)

Các yếu tố rủi ro høy cao

- 1. **Lead time > 30 ngày** — tỉ lệ høy tăng mạnh; >180 ngày đạt 41,7%.
- 2. **No Deposit** — 98,7% booking không cọc, tỉ lệ høy ~27,3%.
- 3. **Online TA** — segment lớn nhất, tỉ lệ høy ~35,5%.
- 4. **Kênh TA/TO** — 80% volume, tỉ lệ høy ~31,5%.
- 5. **Online TA × TA/TO** (heatmap) — 50.104 booking, tỉ lệ høy 35,7% — ô rủi ro lớn nhất toàn dataset.
- 6. **Groups × TA/TO** — tỉ lệ høy 36,2%, cao nhất trong các ô có volume đáng kể.

Các yếu tố nên giảm (høy thấp)

- 1. **Lead time ≤ 30 ngày** — tỉ lệ høy ~16,8%.
- 2. **Corporate segment** — tỉ lệ høy ~12,8%.
- 3. **Kênh Direct / Corporate** — tỉ lệ høy ~15,1–13,6%.
- 4. **Direct × TA/TO** — tỉ lệ høy 3,7% (217 booking); **Online TA × Direct** — 5,6% (126 booking).
- 5. **Corporate × Corporate** — 3.410 booking, tỉ lệ høy 13,0% — segment + channel nên giảm nhất theo volume.

Ma trận ưu tiên can thiệp

Mức ưu tiên	Tổng hợp các trọng	Lý do
Cao	Online TA × TA/TO + lead_time > 60 ngày + No Deposit	~50k booking, cancel rate 35,7%; impact lớn nhất toàn hệ thống
Cao	Groups × TA/TO + lead_time dài	Cancel rate 36,2% — cao nhất các ô volume đáng kể
Trung bình	Offline TA/TO × TA/TO	Volume lớn (12k) nhưng rate thấp hơn (15,1%) — theo dõi, chia sẻ can thiệp mạnh
Thấp	Corporate × Corporate / Direct × TA/TO + lead_time ngắn	Tỉ lệ høy thấp, ít cần can thiệp khẩn

Ghi ý hướng xử lý (Stage 2+)

- **Revenue management:** áp dụng chính sách cọc/refund khác nhau theo lead_time bin (mức biệt >30 và >180 ngày).
- **Channel strategy:** thúc đẩy chuyển dịch từ TA/TO sang Direct cho segment có thể tiếp cận trực tiếp.
- **Segment targeting:** ưu tiên giảm chân Online TA (overbooking policy, deposit, reminder) thay vì can thiệp tăng mới.
- **Feature engineering (modeling):** lead_time, deposit_type, market_segment, distribution_channel và các interaction (lead_time × deposit_type, market_segment × distribution_channel) là candidate feature mạnh cho mô hình dự báo høy.

Phân tích — Phân tích dữ liệu

#	Loại biểu đồ	Biến phân tích
1	Grouped + Stacked histogram	lead_time_bin × is_canceled
2	Histogram + KDE (dual Y)	lead_time × is_canceled
3	2 subplot (histogram bin + KDE)	lead_time × is_canceled
4	Boxplot + Violin	is_canceled → lead_time
5	Line chart	lead_time_bin → cancellation_rate
6	Bar chart	deposit_type → cancellation_rate
7	Stacked bar 100%	deposit_type × is_canceled
8	Horizontal bar	market_segment → cancellation_rate
9	Dual-axis (bar + line)	market_segment → volume & rate
10	Bar chart	distribution_channel → cancellation_rate
11	Heatmap	market_segment × distribution_channel → cancellation_rate

Tài liệu hướng dẫn tạo kết quả EDA trên hotel_bookings_v4.csv. Cập nhật lần cuối: 3/7/2026 — Stage 1 (key dedup mới, 82.811 booking).