

EDA Stage 1: Cancellation Analysis

Nguồn dữ liệu:

hotel_bookings_v4.csv

Phạm vi:

82.811 booking | Tỷ lệ hủy tổng thể: **28,12%** (23.284 booking bị hủy)

Notebook tham chiếu:


02_eda_stage1_cancellation.ipynb

Mục tiêu phân tích

Giai đoạn EDA Stage 1 tập trung khám phá mối quan hệ giữa **tỷ lệ hủy phòng (is_canceled)** và các yếu tố hành vi đặt phòng: thời gian đặt trước (lead_time), loại tiền cọc (deposit_type), phân khúc thị trường (market_segment) và kênh phân phối (distribution_channel). Mười một biểu đồ dưới đây được nhóm theo từng chiều phân tích, kèm insight có thể hành động được.

Nhóm 1 — Lead time (Biểu đồ 1 → 5)

Biểu đồ 1: Histogram số booking theo lead_time bin (tách theo is_canceled)




Mô tả: Grouped bar + stacked bar 100% — trục X = khoảng lead_time (0–30, 31–60, 61–90, 91–180, >180 ngày), trục Y = số lượng booking, tách màu theo Không hủy / Đã hủy.

Insight:

Lead time bin	Tổng booking	Đã hủy	Tỷ lệ hủy
0–30 ngày	33.039	5.559	16,8%
31–60 ngày	12.776	4.115	32,2%
61–90 ngày	8.967	2.978	33,2%
91–180 ngày	17.355	6.178	35,6%
> 180 ngày	10.674	4.454	41,7%

- Bin **0–30 ngày** chiếm **~39,9%** tổng booking và có volume không hủy lớn nhất (27.480 booking) — đây là nhóm "an toàn" nhưng vẫn đóng góp **23,9%** tổng số booking bị hủy.
- Bin **91–180 ngày** có volume cao thứ hai (17.355) và đóng góp **26,5%** tổng cancellation — rủi ro tập trung ở khoảng đặt trước trung-dài hạn.
- Stacked bar 100% cho thấy tỷ lệ phần "Đã hủy" tăng dần rõ rệt từ bin 0–30 sang >180, xác nhận lead_time dài hơn → xác suất hủy cao hơn.

Biểu đồ 2: Histogram + KDE overlay (trục Y kép)




Mô tả: Histogram count theo lead_time liên tục (trục Y trái) kết hợp đường KDE density (trục Y phải), tách theo `is_canceled`.

Insight:

- Phân bố lead_time của booking **không hủy** tập trung mạnh ở vùng **0–100 ngày**, đỉnh density cao nhất quanh **30–60 ngày**.
- Booking **đã hủy** có phân bố dịch sang phải (lead_time cao hơn), đỉnh density nằm ở khoảng **60–120 ngày** và vẫn còn đuôi dài đến >300 ngày.
- Hai đường KDE giao nhau ở khoảng **~45–55 ngày**: dưới ngưỡng này booking không hủy chiếm ưu thế; trên ngưỡng này booking hủy trở nên phổ biến hơn tương đối.

Biểu đồ 3: Histogram theo bin + KDE liên tục (2 subplot)

Phân bố lead_time theo is_canceled




Mô tả: Subplot trái = histogram rời theo bin; subplot phải = KDE lead_time liên tục — cả hai tách theo trạng thái hủy.

Insight:

- Histogram theo bin làm rõ **bước nhảy lớn nhất** về tỷ lệ hủy xảy ra giữa bin **0–30** (16,8%) và **31–60** (32,2%) — gần **gấp đôi**.
- KDE liên tục bổ sung góc nhìn: booking hủy không chỉ "dịch phải" mà còn **phân tán rộng hơn** (độ lệch chuẩn cao hơn), phản ánh sự không chắc chắn cao hơn ở các booking đặt xa ngày đến.
- Kết hợp hai subplot: rủi ro hủy tăng **đột biến** sau 30 ngày lead_time, không phải tăng tuyến tính mượt.

Biểu đồ 4: Boxplot + Violin plot (lead_time theo is_canceled)

Phân bố lead_time theo trạng thái hủy




Mô tả: Trục X = trạng thái hủy, trục Y = lead_time (ngày).

Insight:

Trạng thái	Số booking	Mean	Median	Std
Không hủy (0)	59.527	68,2 ngày	37 ngày	79,1
Đã hủy (1)	23.284	104,9 ngày	79 ngày	91,3

- Median lead_time của booking hủy (**79 ngày**) cao hơn **gấp ~2.1 lần** so với booking không hủy (**37 ngày**).
- Violin plot cho thấy phân bố booking hủy **đẹt và rộng hơn** ở vùng 60–150 ngày, trong khi booking không hủy tập trung hơn quanh median thấp.
- Boxplot: IQR của nhóm hủy cao hơn đáng kể; cả hai nhóm đều có outlier (lead_time >400 ngày) nhưng nhóm hủy có nhiều outlier hơn ở vùng cao.

Biểu đồ 5: Line chart tỷ lệ hủy theo lead_time bin




Mô tả: Trục X = lead_time bin, trục Y = `cancellation_rate (%)`.

Insight:

- Xu hướng **monotonic tăng** rõ rệt: 16,8% → 32,2% → 33,2% → 35,6% → 41,7%.
- Bước nhảy lớn nhất:** từ 0–30 lên 31–60 (+15,4 điểm %). Sau 60 ngày, tỷ lệ hủy tăng chậm hơn nhưng vẫn leo thang.
- Bin **>180 ngày** đạt **41,7%** — gần **2.5 lần** bin 0–30 ngày.
- Hàm ý vận hành:** ngưỡng lead_time **30 ngày** là ranh giới quan trọng để phân loại rủi ro; booking >180 ngày cần chiến lược giữ chân riêng (cọc, xác nhận, pricing linh hoạt).

Nhóm 2 — Deposit type (Biểu đồ 6 → 7)

Biểu đồ 6: Bar chart tỷ lệ hủy theo `deposit_type`




Mô tả: Trục X = deposit_type, trục Y = cancellation_rate (%).

Insight:

Deposit type	Bookings	Cancellation rate
No Deposit	81.767 (98,7%)	27,3%
Non Refund	963 (1,2%)	95,0%
Refundable	81 (<0,1%)	28,4%

- **Non Refund** có tỷ lệ hủy cực cao (~95,0%) — gần như mọi booking loại này đều bị hủy trong dataset. Tuy nhiên volume rất nhỏ (963 booking).
- **No Deposit** chiếm gần toàn bộ dataset và kéo tỷ lệ hủy tổng thể (~28,12%) — đây là nhóm cần ưu tiên can thiệp vì scale lớn.
- **Refundable** có sample quá nhỏ (81) nên tỷ lệ 28,4% cần diễn giải thận trọng.

Biểu đồ 7: Stacked bar 100% — Không hủy vs Đã hủy theo deposit_type



Mô tả: Trục X = deposit_type, trục Y = tỷ lệ (%), stack theo is_canceled .


Insight:

Deposit type	Không hủy	Đã hủy
No Deposit	72,7%	27,3%
Non Refund	5,0%	95,0%
Refundable	71,6%	28,4%

- **No Deposit:** cứ 4 booking thì hơn 1 booking bị hủy — rủi ro hệ thống cao khi không yêu cầu cọc.
- **Non Refund:** gần như toàn bộ stack là "Đã hủy" — loại cọc này **không hiệu quả** trong việc giảm hủy (có thể do cách ghi nhận dữ liệu hoặc chính sách cọc thực tế khác với tên gọi).
- **Refundable:** tỷ lệ hủy cao hơn No Deposit (~28,4% vs 27,3%), phù hợp kỳ vọng vì khách có thể hủy và được hoàn cọc.
- **Kết luận chính sách:** yêu cầu cọc (đặc biệt non-refundable) có liên quan mật thiết với hành vi hủy; cần xem xét mở rộng cọc cho segment rủi ro cao thay vì để No Deposit chiếm 98,7% booking.

Nhóm 3 — Market segment (Biểu đồ 8 → 9)

Biểu đồ 8: Horizontal bar — tỷ lệ hủy theo market_segment (sắp giảm dần)



Mô tả: Trục Y = market_segment, trục X = cancellation_rate (%).


****Insight** (sắp theo tỷ lệ hủy giảm dần):

Market segment	Bookings	Cancellation rate
Undefined	2	100,0%
Online TA	50.391	35,5%
Groups	3.690	31,2%
Aviation	220	19,1%
Offline TA/TO	12.860	15,1%
Direct	11.351	14,9%
Complementary	619	13,1%
Corporate	3.678	12,8%

**Undefined chỉ 2 booking — không có ý nghĩa thống kê.*

- **Online TA** vừa có volume lớn nhất (~60,9% tổng booking) vừa có tỷ lệ hủy cao nhất trong các segment chính — đây là **điểm nóng rủi ro số 1**.
- **Groups** cũng thuộc nhóm rủi ro cao (31,2%) dù volume nhỏ hơn.
- **Corporate** có tỷ lệ hủy thấp nhất (12,8%) — segment ổn định, thường là khách doanh nghiệp có cam kết cao hơn.
- **Direct** và **Offline TA/TO** ở mức trung bình-thấp (~14,9–15,1%), thấp hơn đáng kể so với Online TA.

Biểu đồ 9: Dual-axis — Volume vs cancellation rate theo market_segment



Mô tả: Cột = số booking (sắp theo volume giảm dần), đường = cancellation_rate (%).


Insight:

- **Online TA** nổi bật: cột cao nhất (50.391) và đường cancellation cao (35,5%) — segment "vừa to vừa rủi ro".
- **Offline TA/TO** (12.860 booking, 15,1%) và **Direct** (11.351, 14,9%) có volume đáng kể nhưng tỷ lệ hủy thấp hơn nhiều — hiệu quả hơn về mặt giữ booking.
- **Corporate** (3.678, 12,8%) và **Groups** (3.690, 31,2%) có volume tương đương nhưng tỷ lệ hủy **chênh lệch gần 2.4 lần** — cùng quy mô nhưng rủi ro rất khác nhau.
- **Aviation** (220, 19,1%) và **Complementary** (619, 13,1%) volume nhỏ, ít ảnh hưởng đến tổng cancellation nhưng vẫn hữu ích cho phân khúc chiến lược.

Hàm ý: ưu tiên can thiệp tại **Online TA** (impact lớn nhất lên tổng số booking hủy) thay vì tập trung đồng đều tất cả segment.

Nhóm 4 — Distribution channel (Biểu đồ 10 → 11)

Biểu đồ 10: Bar chart tỷ lệ hủy theo `distribution_channel`




Mô tả: Trục X = distribution_channel (Direct, Corporate, TA/TO, GDS), trục Y = cancellation_rate (%).

Insight:

Distribution channel	Bookings	Cancellation rate
TA/TO	65.956 (79,6%)	31,5%
GDS	172 (0,2%)	19,8%
Direct	12.291 (14,8%)	15,1%
Corporate	4.387 (5,3%)	13,6%

- **TA/TO** chiếm ~80% booking và có tỷ lệ hủy cao nhất (31,5%) — kênh OTA/travel agent là nguồn chính của cancellation.
- **Direct** (15,1%) và **Corporate** (13,6%) có tỷ lệ hủy thấp hơn ~50% so với TA/TO — đặt trực tiếp hoặc qua kênh doanh nghiệp ổn định hơn.
- **GDS** có tỷ lệ 19,8% nhưng sample rất nhỏ (172 booking) — cần thận trọng khi kết luận.
- Phân tích riêng theo channel chưa phân tách được sự khác biệt **bên trong** từng market segment — cần Biểu đồ 11 để làm rõ.

Biểu đồ 11: Heatmap market_segment × distribution_channel



Mô tả: Trục X = distribution_channel, trục Y = market_segment, màu = cancellation_rate trung bình (%) của từng cặp (segment, channel). Ô trống (NaN) = không có booking cho cặp đó.

Mã trận cancellation rate (%)

Market segment ↓ / Channel →	Direct	Corporate	TA/TO	GDS	Undefined
Online TA	5,6	18,2	35,7	20,5	100,0
Groups	19,2	15,8	36,2	—	—
Offline TA/TO	21,4	7,9	15,1	18,2	—
Direct	15,2	10,8	3,7	0,0	50,0
Complementary	12,6	18,2	10,4	—	—
Corporate	10,6	13,0	11,8	—	—
Aviation	—	19,5	10,0	—	—
Undefined	—	—	—	—	100,0

*Sample rất nhỏ (≤ 2 booking) — chỉ mang tính tham khảo.

Mã trận volume (số booking)

Market segment ↓ / Channel →	Direct	Corporate	TA/TO	GDS	Undefined
Online TA	126	33	50.104	127	1
Groups	478	507	2.705	—	—
Offline TA/TO	14	76	12.726	44	—

Market segment ↓ / Channel →	Direct	Corporate	TA/TO	GDS	Undefined
Direct	11.057	74	217	1	2
Complementary	475	77	67	—	—
Corporate	141	3.410	127	—	—
Aviation	—	210	10	—	—
Undefined	—	—	—	—	2

Insight:

- **Tổ hợp rủi ro cao nhất (volume lớn): Online TA × TA/TO** — 50.104 booking, tỷ lệ hủy **35,7%** (~17.866 booking hủy ước tính). Đây là ô "đỏ" lớn nhất trên heatmap, giải thích phần lớn cancellation toàn hệ thống.
- **Tổ hợp rủi ro cao thứ hai: Groups × TA/TO** — 2.705 booking, tỷ lệ hủy **36,2%** (cao hơn cả Online TA × TA/TO về mặt tỷ lệ).
- **Tổ hợp ổn định bất ngờ: Direct × TA/TO** — chỉ 217 booking nhưng tỷ lệ hủy **3,7%** (thấp nhất trong các ô có $n \geq 50$). Segment Direct đặt qua kênh TA/TO hành xử rất khác so với Online TA qua cùng kênh.
- **Online TA × Direct** — 126 booking, tỷ lệ hủy **5,6%**: khi Online TA chuyển sang kênh Direct, rủi ro giảm mạnh so với TA/TO (35,7% → 5,6%).
- **Corporate segment** ổn định trên mọi kênh có dữ liệu: Corporate × Corporate (3.410 booking, 13,0%), Corporate × Direct (10,6%), Corporate × TA/TO (11,8%) — đều dưới mức trung bình chung (28,12%).
- **Offline TA/TO × TA/TO** — 12.726 booking (volume lớn thứ hai) nhưng tỷ lệ hủy chỉ **15,1%**, thấp hơn nhiều so với Online TA × TA/TO dù cùng kênh TA/TO → **market segment quan trọng hơn channel** trong việc giải thích hủy.
- **Groups × Direct** (478 booking, 19,2%) cao hơn Groups × Corporate (15,8%) — kênh Direct không luôn "an toàn" nếu segment vốn rủi ro cao.
- **Aviation × TA/TO** (10 booking, 10,0%) và **Direct × GDS** (1 booking, 0%) — không đủ sample để kết luận.

Hàm ý chiến lược từ heatmap:

- Rủi ro hủy không chỉ do kênh TA/TO mà do **sự giao thoa segment × channel** — cùng kênh TA/TO, Online TA (35,7%) và Offline TA/TO (15,1%) chênh lệch **~21 điểm %**.
- Can thiệp nên **target theo ô cụ thể** (vd. Online TA + TA/TO + lead_time dài) thay vì penalize toàn bộ kênh TA/TO.
- Feature interaction `market_segment × distribution_channel` là candidate mạnh cho mô hình predictive (Stage 2).

Tổng hợp insight xuyên suốt (Biểu đồ 1–11)

Các yếu tố rủi ro hủy cao

1. **Lead time > 30 ngày** — tỷ lệ hủy tăng mạnh; >180 ngày đạt 41,7%.
2. **No Deposit** — 98,7% booking không cọc, tỷ lệ hủy ~27,3%.
3. **Online TA** — segment lớn nhất, tỷ lệ hủy ~35,5%.
4. **Kênh TA/TO** — 80% volume, tỷ lệ hủy ~31,5%.
5. **Online TA × TA/TO** (heatmap) — 50.104 booking, tỷ lệ hủy **35,7%** — ô rủi ro lớn nhất toàn dataset.
6. **Groups × TA/TO** — tỷ lệ hủy **36,2%**, cao nhất trong các ô có volume đáng kể.

Các yếu tố ổn định (hủy thấp)

- 1. **Lead time $\leq$ 30 ngày** — tỷ lệ hủy ~16,8%.
- 2. **Corporate segment** — tỷ lệ hủy ~12,8%.
- 3. **Kênh Direct / Corporate** — tỷ lệ hủy ~15,1–13,6%.
- 4. **Direct $\times$ TA/TO** — tỷ lệ hủy **3,7%** (217 booking); **Online TA $\times$ Direct** — **5,6%** (126 booking).
- 5. **Corporate $\times$ Corporate** — 3.410 booking, tỷ lệ hủy **13,0%** — segment + channel ổn định nhất theo volume.

Ma trận ưu tiên can thiệp

Mức ưu tiên	Tổ hợp đặc trưng	Lý do
Cao	Online TA $\times$ TA/TO + lead_time > 60 ngày + No Deposit	~50k booking, cancel rate 35,7%; impact lớn nhất toàn hệ thống
Cao	Groups $\times$ TA/TO + lead_time dài	Cancel rate 36,2% — cao nhất các ô volume đáng kể
Trung bình	Offline TA/TO $\times$ TA/TO	Volume lớn (12k) nhưng rate thấp hơn (15,1%) — theo dõi, chưa cần can thiệp mạnh
Thấp	Corporate $\times$ Corporate / Direct $\times$ TA/TO + lead_time ngắn	Tỷ lệ hủy thấp, ít cần can thiệp khẩn

Gợi ý hướng xử lý (Stage 2+)

- **Revenue management:** áp dụng chính sách cọc/refund khác nhau theo lead_time bin (đặc biệt >30 và >180 ngày).
- **Channel strategy:** thúc đẩy chuyển dịch từ TA/TO sang Direct cho segment có thể tiếp cận trực tiếp.
- **Segment targeting:** ưu tiên giữ chân Online TA (overbooking policy, deposit, reminder) thay vì can thiệp đồng đều.
- **Feature engineering (modeling):** lead_time , deposit_type , market_segment , distribution_channel và các interaction (lead_time $\times$ deposit_type , market_segment $\times$ distribution_channel) là candidate feature mạnh cho mô hình dự báo hủy.

Phụ lục — Định nghĩa biểu đồ

#	Loại biểu đồ	Biến phân tích
1	Grouped + Stacked histogram	lead_time_bin $\times$ is_canceled
2	Histogram + KDE (dual Y)	lead_time $\times$ is_canceled
3	2 subplot (histogram bin + KDE)	lead_time $\times$ is_canceled
4	Boxplot + Violin	is_canceled $\rightarrow$ lead_time
5	Line chart	lead_time_bin $\rightarrow$ cancellation_rate
6	Bar chart	deposit_type $\rightarrow$ cancellation_rate
7	Stacked bar 100%	deposit_type $\times$ is_canceled
8	Horizontal bar	market_segment $\rightarrow$ cancellation_rate
9	Dual-axis (bar + line)	market_segment $\rightarrow$ volume & rate

#	Loại biểu đồ	Biến phân tích
10	Bar chart	distribution_channel → cancellation_rate
11	Heatmap	market_segment × distribution_channel → cancellation_rate

Tài liệu được tạo từ kết quả EDA trên `hotel_bookings_v4.csv` . Cập nhật lần cuối: 3/7/2026 — Stage 1 (key dedup mới, 82.811 booking).