

Correlation Analysis: `is_canceled` vs tất cả biến

Nguồn dữ liệu: `hotel_bookings_v5.csv` (tải tạo từ `v4` + `day_of_week`)

Phạm vi: 82.811 booking | Tỷ lệ hủy tổng thể: **28,12%** (23.284 booking bị hủy)

Notebook tham chiếu: `04_correlation_analysis.ipynb`

Bổ sung EDA: [02 02 EDA Stage 1 — Cancellation](#)

Mục tiêu phân tích

Báo cáo này đo mức độ **tương quan thống kê** giữa biến mục tiêu `is_canceled` và toàn bộ 35 biến còn lại trong dataset, sau đó phân loại từng biến theo khả năng **nhân quả (causation)** so với **tương quan giả / leakage / confounding**.

Phương pháp:

Loại biến	Metric	Ghi chú
Số (22 biến)	Pearson r	Tuyến tính; thêm Spearman để kiểm tra phi tuyến
Phân loại (13 biến)	Cramér's V	Đo mức liên kết với biến nhị phân <code>is_canceled</code>
Kiểm tra confounding	Partial correlation	Kiểm soát <code>deposit_type</code> ↔ <code>lead_time</code>

Lưu ý quan trọng: Correlation $\neq$ Causation. Tương quan cao chỉ cho biết hai biến đồng biến; để gọi là nguyên nhân cần thỏa thứ tự thời gian, cơ chế hợp lý và khả năng can thiệp.

1. Tổng quan kết quả

1.1 Top biến tương quan mạnh nhất (sau khi loại leakage)


Hạng	Biến	Metric	Giá trị	Hướng
1	<code>lead_time</code>	Pearson r	0,196	Dài hơn → hủy nhiều hơn
2	<code>required_car_parking_spaces</code>	Pearson r	-0,189	Cần chỗ đậu xe → ít hủy
3	<code>total_of_special_requests</code>	Pearson r	-0,128	Nhiều yêu cầu đặc biệt → ít hủy
4	<code>market_segment</code>	Cramér's V	0,219	Segment khác nhau → hủy khác nhau
5	<code>adr</code>	Pearson r	0,123	Giá cao hơn một chút ở booking hủy
6	<code>deposit_type</code>	Cramér's V	0,161	Loại cọc liên quan mạnh đến hủy
7	<code>distribution_channel</code>	Cramér's V	0,151	Kênh OTA hủy cao hơn Direct
8	<code>customer_type</code>	Cramér's V	0,118	Transient hủy nhiều hơn Contract

1.2 Biến leakage — loại khỏi modeling

Biến	Metric	Giá trị	Lý do loại
reservation_status	Cramér's V	1,000	Gần như là nhãn của hủy (Canceled = 100%)
reservation_status_date	Cramér's V	0,309	Ngày ghi nhận trạng thái — xảy ra sau hủy
revenue	Pearson r	-0,494	$revenue = adr \times total_nights \times (1 - is_canceled)$ — tương quan cơ học
Occupancy_Rate	Pearson r	-0,163	Biến tổng hợp theo thời gian
RevPAR	Pearson r	0,084	Biến tổng hợp derived

Xác minh công thức `revenue` : **100,0%** dòng khớp `adr × total_nights × (1 - is_canceled)` .

2. Tương quan biến số (Pearson & Spearman)



2.1 Bảng đầy đủ — Pearson với is_canceled

Biến	Pearson r	abs(r)	Diễn giải nhanh
revenue	-0,494	0,494	⚠️ Leakage — hậu quả của hủy
lead_time	0,196	0,196	Đặt trước xa → hủy cao hơn
required_car_parking_spaces	-0,189	0,189	Kế hoạch cụ thể → ít hủy
Occupancy_Rate	-0,163	0,163	⚠️ Biến tổng hợp
total_of_special_requests	-0,128	0,128	Cam kết cao → ít hủy
adr	0,123	0,123	Confounded (segment/OTA)
booking_changes	-0,093	0,093	Hướng nhân quả không rõ
is_repeated_guest	-0,090	0,090	Khách quen → ít hủy
arrival_date_year	0,089	0,089	Xu hướng thời gian
RevPAR	0,084	0,084	⚠️ Biến tổng hợp
stays_in_week_nights	0,079	0,079	Confounded (Groups)
total_nights	0,079	0,079	Confounded
adults	0,076	0,076	Proxy loại booking
children	0,064	0,064	Yếu
previous_bookings_not_canceled	-0,053	0,053	Yếu
stays_in_weekend_nights	0,054	0,054	Yếu
previous_cancellations	0,047	0,047	Lịch sử hủy (Spearman mạnh hơn: +0,12)
babies	-0,023	0,023	Không đáng kể
days_in_waiting_list	0,010	0,010	Không đáng kể
agent	-0,003	0,003	Không đáng kể
arrival_date_day_of_month	0,005	0,005	Không đáng kể
arrival_date_week_number	0,001	0,001	Không đáng kể


Quy ước đọc |r|: < 0,1 yếu · 0,1–0,3 trung bình · > 0,3 mạnh (không tính biến leakage).

2.2 Spearman — top 10 (kiểm tra phi tuyến)

Biến	Spearman ρ	Ghi chú so với Pearson
revenue	-0,770	Phi tuyến mạnh do khối lượng revenue = 0 khi hủy
lead_time	0,233	Cao hơn Pearson (0,196) → quan hệ monotonic, có thể phi tuyến
required_car_parking_spaces	-0,191	Ổn định với Pearson
total_of_special_requests	-0,135	Ổn định
adr	0,138	Ổn định
previous_cancellations	0,121	Mạnh hơn Pearson (0,047) — hiệu ứng ở đuôi phân bố

Biến	Spearman ρ	Ghi chú so với Pearson
booking_changes	-0,124	Mạnh hơn Pearson (-0,093)

3. Tương quan biến phân loại (Cramér's V)



Biến	Cramér's V	Spread tỷ lệ hủy	Số nhóm	Ghi chú
reservation_status	100,0	100,0 pp	3	⚠️ Leakage
reservation_status_date	0,309	100,0 pp	925	⚠️ Hậu quả
market_segment	0,219	87,1 pp	8	Online TA vs Corporate chênh ~23 pp
country	0,202	100,0 pp	178	Nhiều nước sample < 5 — spurious
deposit_type	0,161	67,4 pp	3	Lever chính sách
distribution_channel	0,151	66,2 pp	5	TA/TO vs Corporate
customer_type	0,118	20,5 pp	4	Transient vs Group
assigned_room_type	0,094	98,5 pp	12	Có thể gán sau đặt phòng
arrival_date_month	0,083	10,8 pp	12	Seasonality — confounded
hotel	0,072	6,6 pp	2	City vs Resort
meal	0,061	17,8 pp	5	Yếu-trung bình
reserved_room_type	0,053	72,9 pp	10	Sample nhỏ ở một số loại
day_of_week	0,047	6,3 pp	7	Không đáng kể

3.1 Chi tiết nhóm phân loại quan trọng

deposit_type

Loại cọc	Booking	Tỷ lệ hủy
Non Refund	963	95,0%
Refundable	81	28,4%
No Deposit	81.767	27,3%

- **98,7%** booking là No Deposit → rủi ro hủy mang tính hệ thống.
- Non Refund 95,0% hủy cần diễn giải thận trọng: có thể **reverse causality** (booking rủi ro cao mới bị gán non-refundable) hoặc cách ghi nhận dữ liệu.

market_segment (sắp theo tỷ lệ hủy)

Segment	Booking	Tỷ lệ hủy
Undefined	2	100,0%
Online TA	50.391	35,5%
Groups	3.690	31,2%
Aviation	220	19,1%
Offline TA/TO	12.860	15,1%
Direct	11.351	14,9%
Complementary	619	13,1%
Corporate	3.678	12,8%

distribution_channel

Kênh	Booking	Tỷ lệ hủy
TA/TO	65.956	31,5%
GDS	172	19,8%
Direct	12.291	15,1%
Corporate	4.387	13,6%

customer_type

Loại khách	Booking	Tỷ lệ hủy
Transient	69.939	30,4%
Contract	3.068	16,5%
Transient-Party	9.294	15,8%
Group	510	10,6%


hotel

→ Cả `lead_time` và `deposit_type` đều là candidate causation độc lập, không chỉ đồng biến do biến thứ ba.

5. Phân loại Causation vs Correlation

```
flowchart LR
    subgraph T1["Tier 1 – Causation cao"]
        A[lead_time]
        B[deposit_type]
    end
    subgraph T2["Tier 2 – Causation TB"]
        C[market_segment]
        D[distribution_channel]
        E[previous_cancellations]
        F[total_of_special_requests]
        G[required_car_parking_spaces]
        H[is_repeated_guest]
    end
    subgraph T3["Tier 3 – Confounded"]
        I[adr / hotel / customer_type]
    end
    subgraph L["Leakage – Không dùng"]
        J[reservation_status / revenue]
    end
    T1 --> X[is_canceled]
    T2 --> X
    T3 --> X
    X --> L
```

5.1 Tier 1 — Causation cao (ưu tiên can thiệp chính sách)



Biến	Metric	Cơ chế nhân quả	Hành động gợi ý
lead_time	r = 0,196	Đặt xa → nhiều biến cố → hủy tăng. EDA: 17% (≤ 30 ngày) → 42% (> 180 ngày)	Cọc tiered theo lead_time; reminder trước ngày đến
deposit_type	V = 0,161	Chi phí hủy thay đổi theo chính sách cọc	Mở rộng cọc cho segment rủi ro cao (hiện 98,7% No Deposit)

5.2 Tier 2 — Causation trung bình (feature model + can thiệp gián tiếp)

Biến	Metric	Cơ chế	Ghi chú
market_segment	V = 0,219	Hành vi khác nhau theo segment (OTA vs Corporate)	Kết hợp với channel: Online TA × TA/TO = 35,7%
distribution_channel	V = 0,151	OTA cho phép hủy dễ hơn Direct	TA/TO 31,5% vs Direct 15,1%
previous_cancellations	r = 0,047 ($\rho = 0,121$)	Lịch sử hủy dự báo hành vi tương lai	Behavioral signal
total_of_special_requests	r = -0,128	Yêu cầu cụ thể = cam kết cao	Scoring risk
required_car_parking_spaces	r = -0,189	Kế hoạch chuyến đi cụ thể	Scoring risk
is_repeated_guest	r = -0,090	Loyalty → ít hủy	Retention lever

5.3 Tier 3 — Confounded (tương quan có, nhân quả chưa chắc)

Biến	Vấn đề
adr	Giá cao ở booking hủy do mix Online TA + lead_time dài, không phải giá gây hủy
customer_type , hotel	Gắn với segment và kênh phân phối
booking_changes	Hai chiều: đổi vì sắp hủy hoặc đổi vì đã cam kết
stays_in_week_nights , total_nights , adults	Proxy cho Groups/segment
arrival_date_month	Mùa cao điểm ↔ mix OTA
country , assigned_room_type , reserved_room_type	Sample nhỏ hoặc thời điểm gán không rõ

5.4 Tier 4 — Tương quan yếu (ít giá trị dự báo)

agent , days_in_waiting_list , babies , children , day_of_week , meal , arrival_date_year , arrival_date_week_number , arrival_date_day_of_month , previous_bookings_not_canceled , stays_in_weekend_nights

5.5 Leakage — tuyệt đối không dùng làm feature

reservation_status , reservation_status_date , revenue , Occupancy_Rate , RevPAR

6. Ma trận ưu tiên Feature cho Predictive Modeling

Ưu tiên	Feature	Lý do
P1	lead_time	Causation mạnh nhất; partial corr vẫn 0,177 sau kiểm soát deposit
P1	deposit_type	Lever chính sách trực tiếp
P1	market_segment × distribution_channel	Interaction mạnh hơn từng biến riêng (EDA Stage 1)
P2	previous_cancellations , is_repeated_guest	Behavioral history
P2	total_of_special_requests , required_car_parking_spaces	Tín hiệu cam kết
P3	customer_type , hotel , adr	Có giá trị nhưng confounded — dùng kèm regularization
Loại	reservation_status , revenue , Occupancy_Rate , RevPAR	Data leakage

7. Kết luận

7.1 Insight then chốt

- 1. Trong 35 biến phân tích, chỉ ~8 biến có cơ sở hợp lý để coi là **nguyên nhân tiềm năng** của hủy phòng.
- 2. `lead_time` và `deposit_type` là hai lever nhân quả mạnh nhất và **có thể can thiệp** trực tiếp bằng chính sách revenue management.
- 3. `market_segment` và `distribution_channel` giải thích nhiều variance nhất trong nhóm phân loại ($V \approx 0,15-0,22$), nhưng một phần là proxy hành vi — nên dùng **interaction** thay vì từng biến riêng.
- 4. `revenue` ($r = -0,494$) và `reservation_status` ($V = 1,0$) là **leakage** — tuyệt đối loại khỏi mô hình dự báo.
- 5. Phần lớn biến còn lại có $|r| < 0,1$ hoặc $V < 0,1$ — đóng góp dự báo hạn chế nếu không kết hợp engineering (binning `lead_time` , interaction `segment × channel`).


7.2 Liên kết với EDA Stage 1


Phát hiện Correlation	Khớp EDA Stage 1
<code>lead_time</code> $r = 0,196$	Monotonic 17% → 42%; ngưỡng 30 ngày
<code>deposit_type</code> $V = 0,161$	No Deposit 98,7% volume, 27,3% cancel
<code>market_segment</code> $V = 0,219$	Online TA 35,5% vs Corporate 12,8%
<code>distribution_channel</code> $V = 0,151$	TA/TO 31,5% vs Direct 15,1%
Interaction <code>segment × channel</code>	Online TA × TA/TO: 50.104 booking, 35,7%

7.3 Bước tiếp theo

- **Feature engineering:** `lead_time_bin` (ngưỡng 30/60/180 ngày), `market_segment × distribution_channel` , `lead_time × deposit_type`
- **Modeling:** `06_cancellation_model_v1.ipynb` — Logistic Regression / Random Forest với feature Tier 1–2, loại leakage
- **Đánh giá:** SHAP/feature importance để xác nhận directionality sau khi fit model

Phụ lục — Biểu đồ trong notebook





#	Loại biểu đồ	Nội dung
1	Horizontal bar	Pearson r biến số vs is_canceled
2	Horizontal bar	Cramér's V biến phân loại
3	Heatmap	Ma trận Pearson đầy đủ (20 biến số)
4	Heatmap 1 cột	Tổng hợp tất cả biến vs is_canceled
5	Stacked bar theo tier	Phân loại Causation vs Correlation
6	Bảng	Partial correlation lead_time ↔ deposit_type

Tài liệu được tạo từ kết quả phân tích trên hotel_bookings_v5.csv . Cập nhật lần cuối: 3/7/2026 — Correlation Analysis (key dedup mỗi, 82.811 booking).

