

Kiểm định giả thuyết: Ảnh hưởng của is_canceled

Nguồn dữ liệu: hotel_bookings_v5.csv (tải từ v4 + day_of_week)

Phạm vi: 82.811 booking | Tỷ lệ hủy phòng: 28,12% (~23.284 booking hủy)

Notebook tham chiếu: 05_hypothesis_testing.ipynb

Mức ý nghĩa: $\alpha = 0,05$

Mục tiêu

Kiểm định thống kê xem ba biến lead_time, deposit_type và market_segment có ảnh hưởng đến xác suất hủy phòng (is_canceled) hay không, bằng các test phù hợp với kiểu dữ liệu tương ứng. Bổ sung mô hình logistic regression để đánh giá ảnh hưởng khi đã kiểm soát các yếu tố còn lại.

Tóm tắt phương pháp


Biến	Kiểu dữ liệu	Test chính	Effect size	Mục đích
lead_time	Số (liên tục, lệch phải)	Mann-Whitney U	Rank-biserial r + bootstrap CI	So sánh phân bố lead_time giữa booking hủy / không hủy
lead_time (bin)	Phân loại (5 nhóm)	Chi-squared	Cramér's V	Kiểm tra tỷ lệ hủy khác nhau theo nhóm lead_time
deposit_type	Phân loại (3 mức)	Chi-squared	Cramér's V	Kiểm tra mức giá giữa các loại và trạng thái hủy
market_segment	Phân loại (8 mức)	Chi-squared	Cramér's V	Kiểm tra mức giá phân khúc và trạng thái hủy
3 biến ảnh hưởng	Hỗn hợp	Logistic regression	Odds ratio, Pseudo R^2	Mô hình đa biến + LR test

Lưu ý phương pháp: Với $n \approx 82.811$, p-value rất dễ nhỏ hơn α ngay cả khi chênh lệch nhỏ — cần kiểm tra kèm effect size (rank-biserial r , Cramér's V, OR).

Kết quả tổng hợp

Giả thuyết	Biến	Test	p-value	Effect size	Kết luận ($\alpha = 0,05$)
H1	lead_time	Mann-Whitney U	≈ 0	$ r = 0,299$	Bác bỏ H ₀
H1b	lead_time_bin	Chi-squared	≈ 0	$V = 0,213$	Bác bỏ H ₀
H2	deposit_type	Chi-squared	≈ 0	$V = 0,161$	Bác bỏ H ₀
H3	market_segment	Chi-squared	≈ 0	$V = 0,219$	Bác bỏ H ₀
H4	3 biến độc lập thời gian	Logistic (LR test)	≈ 0	Pseudo R ² = 0,094	Bác bỏ H ₀

H1 — lead_time (Mann-Whitney U)



H₀: Phân bố lead_time giống nhau giữa booking hủy và không hủy.

H₁: Hai phân bố khác nhau.

Thống kê	Giá trị
----------	---------


U statistic	900.561.203
p-value	≈ 0
Rank-biserial r	0,299
Median — không hủy	37 ngày
Median — đã hủy	79 ngày
Mean — không hủy	68,2 ngày
Mean — đã hủy	104,9 ngày

Diễn giải:

- Booking đã hủy có lead_time cao hơn rõ rệt: median gấp ~2.1 lần (79 vs 37 ngày).
- Effect size $|r| = 0,299 \rightarrow$ mức ảnh hưởng trung bình (theo quy tắc $|r| \approx 0,1 / 0,3 / 0,5$ cho nhỏ / TB / lớn).
- Bootstrap 95% CI cho chênh median (hủy – không hủy) đáng kể và không chứa 0 $\rightarrow$ xác nhận chênh lệch có ý nghĩa thống kê.

Kết luận: Bác bỏ H_0 — lead_time có association với is_canceled; thời điểm càng xa ngày lên, rủi ro hủy càng cao.

H1b — lead_time_bin (Chi-squared)



H_1 : Nhóm lead_time bin và is_canceled khác biệt có ý nghĩa.

H_0 : Tỷ lệ hủy khác nhau giữa các bin.

Thống kê	Giá trị
χ^2	3764,0
df	4
p-value	≈ 0
Cramér's V	0,213
Min expected count	2521,3

Tỷ lệ hủy theo bin:

Lead time bin	Booking	Tỷ lệ hủy
0–30 ngày	33.039	16,8%
31–60 ngày	12.776	32,2%
61–90 ngày	8.967	33,2%
91–180 ngày	17.355	35,6%
>180 ngày	10.674	41,7%


Diễn giải:

- Bước hủy lên nhót: t bin 0–30 (17%) lên 31–60 (32%) — g n g p ôi.
- Tỷ lệ hủy tng d n theo bin; Cramér's V = 0,213 → association trung bình–khá (m nh nh t trong các test chi-squared trên lead_time).

K t lu n: B c b H — nh m lead_time c nh h ng n t l h y.

H2 — deposit_type (Chi-squared)

H2 — deposit_type vs is_canceled



H₀: deposit_type và is_canceled độc lập.
H₁: Có association giữa hai biến.

Thống kê	Giá trị
χ^2	2157,5
df	2
p-value	≈ 0
Cramér's V	0,161
Min expected count	22,8

Tỷ lệ hủy theo loại cọc:

Loại cọc	Booking	Tỷ lệ hủy
Non Refund	963	95,0%
Refundable	81	28,4%
No Deposit	81.767	27,3%


Diễn giải:

- 98,7% booking là No Deposit → rủi ro hủy mang tính hệ thống nên nhóm không cọc.

- *Non Refund* có tỷ lệ hủy 95,0% còn dĩ nhiên giá thì thấp: có thể **reverse causality** (booking rẻ thì rõ cao mức bị gán non-refundable) hoặc do cách ghi nhận dữ liệu — không nên coi là tác động nhân quả đơn thuần.
- Ở *Refundable* (n = 81) có expected count thấp → kết quả chi-squared tăng thì vẫn hợp lý những post-hoc cho nhóm này cần thận trọng.

Kết luận: Bác bỏ H_0 — `deposit_type` liên quan đến `is_canceled` (V = 0,161, mức trung bình).

H3 — market_segment (Chi-squared)



H_0 : market_segment và is_canceled độc lập.
 H_1 : Có association giữa phân khúc thị trường và tỷ lệ hủy.

Thống kê	Giá trị
χ^2	3960,4
df	7
p-value	≈ 0
Cramér's V	0,219
Min expected count	0,56

Tỷ lệ hủy theo segment (sắp giảm dần):

Segment	Booking	Tỷ lệ hủy
---------	---------	-----------


Undefined	2	100,0%
Online TA	50.391	35,5%
Groups	3.690	31,2%
Aviation	220	19,1%
Offline TA/TO	12.860	15,1%
Direct	11.351	14,9%
Complementary	619	13,1%
Corporate	3.678	12,8%

Diễn giải:

- Cramér's V = 0,219 → association **mạnh mẽ** trong ba biến phân loại.
- Online TA** chiếm ~61% booking và có **tỷ lệ hủy** cao nhất trong các segment (35,5%).
- Corporate** có **tỷ lệ hủy** thấp nhất (12,8%) trong nhóm có sample **đủ lớn**.
- Segment *Undefined* (n = 2) có expected count **thấp** → standardized residual không **đáng tin cậy** cho nhóm này.

Kết luận: Các biến `market_segment` **ảnh hưởng** đến **tỷ lệ hủy**.

H4 — Logistic Regression đa biến



Mô hình: `is_canceled ~ lead_time + deposit_type + market_segment`

Baseline: `deposit_type = No Deposit, market_segment = Direct`

Thống kê mô hình	Giá trị
n	82.811
Pseudo R ² (McFadden)	0,094

LR χ^2 (vs null)	9228,9
df	10
p-value (LR test)	≈ 0

Hệ số đáng chú ý ($p < 0,05$):

Biến	OR (95% CI gần đúng)	Diễn giải
lead_time (+1 ngày)	1,005	Mỗi thêm 1 ngày mất trực → odds hủy tăng ~0,5%
lead_time (+30 ngày)	1,158	Mỗi thêm 30 ngày → odds hủy tăng ~15,8%
deposit_type_Non Refund	Rất cao	Mối liên quan hủy (cần diễn giải thêm trong)
market_segment_Online TA	> 1	Xác suất hủy cao hơn baseline Direct
market_segment_Offline TA/TO	< 1	Xác suất hủy thấp hơn Direct
market_segment_Corporate	< 1	Xác suất hủy thấp hơn Direct
market_segment_Groups	< 1	Xác suất hủy thấp hơn Direct


Biến không có ý nghĩa ($p \geq 0,05$): deposit_type_Refundable, market_segment_Complementary, market_segment_Direct (đã là baseline), market_segment_Undefined.

Diễn giải:

- Mô hình giải thích ~9,4% biến thiên log-likelihood (Pseudo R^2) — giúp lý giải bài toán hành vi khách hàng phức tạp; còn nhiều yếu tố chưa đưa vào mô hình.
- Sau khi kiểm soát deposit_type và market_segment, lead_time vẫn có ý nghĩa → không phải confounding giữa hai biến còn lại.
- LR test bác bỏ mô hình null → ít nhất một predictor trong mô hình có giá trị.

Kết luận: Bác bỏ H0 tăng trưởng — cả ba nhóm biến đều đóng góp vào diễn biến hủy trong mô hình đa biến.

So sánh effect size



Test	Biến	Metric	Giá trị	Xếp hạng tổng thể
Mann-Whitney U	lead_time	rank-biserial r	0,299	Cao
Chi-squared	lead_time_bin	Cramér's V	0,213	Cao
Chi-squared	market_segment	Cramér's V	0,219	Cao nhất (phân loại)
Chi-squared	deposit_type	Cramér's V	0,161	Trung bình
Logistic	3 biến	Pseudo R ²	0,094	Mô hình tổng hợp

Kết luận chung

- lead_time** — Booking ngày có thời gian chờ trực dài hơn đáng kể; rủi ro tăng mạnh sau **30 ngày** và tiếp tục tăng theo bin.
- deposit_type** — Liên quan thống kê rõ rệt đến ngày; *Non Refund* gần với thời hạn hủy cao nhất trong các phân tích nhân quả thêm.
- market_segment** — Ảnh hưởng mạnh nhất trong các biến phân loại; **Online TA** là nguồn rủi ro hủy chính, **Corporate** tiếp theo là doanh nghiệp.
- Mô hình đa biến xác nhận cả ba biến trên có ý nghĩa (hệ số đóng góp) khi kiểm soát lẫn nhau.

Khuyến nghị hành động

Ưu tiên	Hành động	Các số chỉ số kiểm soát
Cao	Theo dõi sát booking lead_time > 30 ngày , các bin > 180 ngày	H1, H1b
Cao	Rà soát chính sách / forecast riêng cho Online TA	H3, H4
Trung bình	Phân tích sâu nhóm Non Refund (nhân quả vs gán nhãn)	H2

Trung bình	Ưu tiên giảm chi phí / giảm overbooking risk cho Corporate, Direct	H3
Thấp	Bổ sung biến (distribution_channel, customer_type, ...) vào mô hình v2	Pseudo R ² còn thấp

Hỏi đáp

- Kích thước mẫu lớn → p-value gần 0 không đáng nghi ngờ chênh lệch lớn với mức kinh doanh; luôn kèm effect size.
- **Non Refund** và **Undefined** segment có thể bị confounding / sample nhỏ.
- Kiểm định mô tả **association**, không khẳng định nhân quả thực tế.
- Logistic regression giúp phân quan hệ log-linear trên lead_time; quan hệ thực tế có thể phi tuyến (đã phân ánh mắt phần qua bin ở H1b).

Tài liệu liên quan

- 02_eda_stage1_cancellation.ipynb — EDA trực quan cancellation
- 04_correlation_analysis.ipynb — Tổng quan tổng hợp
- 02_eda_stage1_cancellation_analysis.md — Báo cáo EDA Stage 1
- 04_correlation_analysis_is_canceled.md — Báo cáo correlation

Tài liệu được tạo từ kết quả kiểm định trên hotel_bookings_v5.csv. Cập nhật lần cuối: 3/7/2026 — Hypothesis Testing (key dedup mới, 82.811 booking).