

Kiểm định giả thuyết: Ảnh hưởng đến `is_canceled`

Nguồn dữ liệu: `hotel_bookings_v5.csv` (tải tạo từ `v4` + `day_of_week`)

Phạm vi: 82.811 booking | Tỷ lệ hủy tổng thể: **28,12%** (~23.284 booking bị hủy)

Notebook tham chiếu: `05_hypothesis_testing.ipynb`

Mức ý nghĩa: $\alpha = 0,05$

Mục tiêu

Kiểm định thống kê xem ba biến `lead_time`, `deposit_type` và `market_segment` có ảnh hưởng đến xác suất hủy phòng (`is_canceled`) hay không, bằng các test phù hợp với kiểu dữ liệu từng biến. Bổ sung mô hình **logistic regression** đa biến để đánh giá đồng thời khi đã kiểm soát các yếu tố còn lại.

Tóm tắt phương pháp

Biến	Kiểu dữ liệu	Test chính	Effect size	Mục đích
<code>lead_time</code>	Số (liên tục, lệch phải)	Mann-Whitney U	Rank-biserial r + bootstrap CI	So sánh phân bố <code>lead_time</code> giữa booking hủy / không hủy
<code>lead_time</code> (bin)	Phân loại (5 nhóm)	Chi-squared	Cramér's V	Kiểm tra tỷ lệ hủy khác nhau theo nhóm <code>lead_time</code>
<code>deposit_type</code>	Phân loại (3 mức)	Chi-squared	Cramér's V	Kiểm tra độc lập giữa loại cọc và trạng thái hủy
<code>market_segment</code>	Phân loại (8 mức)	Chi-squared	Cramér's V	Kiểm tra độc lập giữa phân khúc và trạng thái hủy
3 biến đồng thời	Hỗn hợp	Logistic regression	Odds ratio, Pseudo R^2	Mô hình đa biến + LR test


Lưu ý phương pháp: Với $n \approx 82.811$, p-value rất dễ nhỏ hơn α ngay cả khi chênh lệch nhỏ — cần đọc kết quả kèm **effect size** (rank-biserial r , Cramér's V, OR).

Kết quả tổng hợp

Giả thuyết	Biến	Test	p-value	Effect size	Kết luận ($\alpha = 0,05$)
H1	<code>lead_time</code>	Mann-Whitney U	≈ 0	$ r = 0,299$	Bác bỏ H_0
H1b	<code>lead_time_bin</code>	Chi-squared	≈ 0	$V = 0,213$	Bác bỏ H_0
H2	<code>deposit_type</code>	Chi-squared	≈ 0	$V = 0,161$	Bác bỏ H_0
H3	<code>market_segment</code>	Chi-squared	≈ 0	$V = 0,219$	Bác bỏ H_0
H4	3 biến đồng thời	Logistic (LR test)	≈ 0	Pseudo $R^2 = 0,094$	Bác bỏ H_0

H1 — lead_time (Mann-Whitney U)

H1 — Mann-Whitney U: lead_time vs is_canceled



H₀: Phân bố lead_time giống nhau giữa booking hủy và không hủy.

H₁: Hai phân bố khác nhau.


Thống kê	Giá trị
U statistic	900.561.203
p-value	≈ 0
Rank-biserial <i>r</i>	0,299
Median — không hủy	37 ngày
Median — đã hủy	79 ngày
Mean — không hủy	68,2 ngày
Mean — đã hủy	104,9 ngày

Diễn giải:

- Booking **đã hủy** có lead_time cao hơn rõ rệt: median gấp **~2.1 lần** (79 vs 37 ngày).
- Effect size $|r| = 0,299 \rightarrow$ mức ảnh hưởng **trung bình** (theo quy ước $|r| \approx 0,1 / 0,3 / 0,5$ cho nhỏ / TB / lớn).
- Bootstrap 95% CI cho chênh median (hủy – không hủy) dương và không chứa 0 $\rightarrow$ xác nhận chênh lệch có ý nghĩa thực tế.

Kết luận: Bác bỏ H_0 — `lead_time` có association với `is_canceled` ; đặt trước càng xa ngày đến, rủi ro hủy càng cao.

H1b — `lead_time_bin` (Chi-squared)



H_0 : Nhóm `lead_time` bin và `is_canceled` độc lập.

H_1 : Tỷ lệ hủy khác nhau giữa các bin.

Thống kê	Giá trị
χ^2	3764,0
df	4
p-value	≈ 0
Cramér's V	0,213
Min expected count	2521,3

Tỷ lệ hủy theo bin:


Lead time bin	Booking	Tỷ lệ hủy
0–30 ngày	33.039	16,8%
31–60 ngày	12.776	32,2%
61–90 ngày	8.967	33,2%
91–180 ngày	17.355	35,6%
> 180 ngày	10.674	41,7%

Diễn giải:

- Bước nhảy lớn nhất: từ bin **0–30** (17%) lên **31–60** (32%) — gần **gấp đôi**.
- Tỷ lệ hủy tăng dần theo bin; Cramér's V = 0,213 → association **trung bình–khá** (mạnh nhất trong các test chi-squared trên lead_time).

Kết luận: Bác bỏ H_0 — nhóm lead_time có ảnh hưởng đến tỷ lệ hủy.

H2 — deposit_type (Chi-squared)



H₀: deposit_type và is_canceled độc lập.

H₁: Có association giữa loại cọc và tỷ lệ hủy.

Thống kê	Giá trị
χ^2	2157,5
df	2
p-value	≈ 0
Cramér's V	0,161
Min expected count	22,8

Tỷ lệ hủy theo loại cọc:


Loại cọc	Booking	Tỷ lệ hủy
Non Refund	963	95,0%
Refundable	81	28,4%
No Deposit	81.767	27,3%

Diễn giải:

- **98,7%** booking là *No Deposit* → rủi ro hủy mang tính hệ thống ở nhóm không cọc.
- *Non Refund* có tỷ lệ hủy 95,0% cần diễn giải thận trọng: có thể **reverse causality** (booking rủi ro cao mới bị gán non-refundable) hoặc do cách ghi nhận dữ liệu — không nên coi là tác động nhân quả đơn thuần.
- Ô *Refundable* (n = 81) có expected count thấp → kết quả chi-squared tổng thể vẫn hợp lệ nhưng post-hoc cho nhóm này cần thận trọng.

Kết luận: Bác bỏ H_0 — `deposit_type` liên quan đến `is_canceled` (V = 0,161, mức trung bình).

H3 — `market_segment` (Chi-squared)



H_0 : `market_segment` và `is_canceled` độc lập.
 H_1 : Có association giữa phân khúc thị trường và tỷ lệ hủy.

Thống kê	Giá trị
χ^2	3960,4
df	7
p-value	≈ 0
Cramér's V	0,219
Min expected count	0,56

Tỷ lệ hủy theo segment (sắp giảm dần):

Segment	Booking	Tỷ lệ hủy
Undefined	2	100,0%


Segment	Booking	Tỷ lệ hủy
Online TA	50.391	35,5%
Groups	3.690	31,2%
Aviation	220	19,1%
Offline TA/TO	12.860	15,1%
Direct	11.351	14,9%
Complementary	619	13,1%
Corporate	3.678	12,8%

Diễn giải:

- Cramér's V = 0,219 → association **mạnh nhất** trong ba biến phân loại.
- **Online TA** chiếm ~61% booking và có tỷ lệ hủy cao nhất trong các segment lớn (35,5%).
- **Corporate** có tỷ lệ hủy thấp nhất (12,8%) trong nhóm có sample đủ lớn.
- Segment *Undefined* (n = 2) có expected count rất thấp → standardized residual không đáng tin cậy cho nhóm này.

Kết luận: Bác bỏ H_0 — `market_segment` ảnh hưởng đến tỷ lệ hủy.

H4 — Logistic Regression đa biến



Mô hình: `is_canceled ~ lead_time + deposit_type + market_segment`

Baseline: `deposit_type = No Deposit` , `market_segment = Direct`

Thống kê mô hình	Giá trị
n	82.811
Pseudo R ² (McFadden)	0,094
LR χ^2 (vs null)	9228,9
df	10
p-value (LR test)	≈ 0

Hệ số đáng chú ý ($p < 0,05$):

Biến	OR (95% CI gần đúng)	Diễn giải
lead_time (+1 ngày)	1,005	Mỗi thêm 1 ngày đặt trước → odds hủy tăng ~0,5%
lead_time (+30 ngày)	1,158	Mỗi thêm 30 ngày → odds hủy tăng ~15,8%
deposit_type_Non Refund	Rất cao	Mạnh liên quan hủy (cần diễn giải thận trọng)
market_segment_Online TA	> 1	Xác suất hủy cao hơn baseline Direct
market_segment_Offline TA/TO	< 1	Xác suất hủy thấp hơn Direct
market_segment_Corporate	< 1	Xác suất hủy thấp hơn Direct
market_segment_Groups	< 1	Xác suất hủy thấp hơn Direct


Biến không có ý nghĩa ($p \geq 0,05$): deposit_type_Refundable , market_segment_Complementary , market_segment_Direct (đã là baseline ẩn), market_segment_Undefined .

Diễn giải:

- Mô hình giải thích ~**9,4%** biến thiên log-likelihood (Pseudo R^2) — hợp lý với bài toán hành vi khách hàng phức tạp; còn nhiều yếu tố chưa đưa vào mô hình.
- Sau khi kiểm soát deposit_type và market_segment , **lead_time vẫn có ý nghĩa** → không phải confounding đơn giản từ hai biến còn lại.
- LR test bác bỏ mô hình null → ít nhất một predictor trong mô hình có giá trị.

Kết luận: Bác bỏ H_0 tổng thể — cả ba nhóm biến đều đóng góp vào dự đoán hủy trong mô hình đa biến.

So sánh effect size



Test	Biến	Metric	Giá trị	Xếp hạng tương đối
Mann-Whitney U	lead_time	rank-biserial r	0,299	Cao
Chi-squared	lead_time_bin	Cramér's V	0,213	Cao
Chi-squared	market_segment	Cramér's V	0,219	Cao nhất (phân loại)
Chi-squared	deposit_type	Cramér's V	0,161	Trung bình
Logistic	3 biến	Pseudo R^2	0,094	Mô hình tổng hợp

Kết luận chung

- 1. `lead_time` — Booking hủy có thời gian đặt trước dài hơn đáng kể; rủi ro tăng mạnh sau **30 ngày** và tiếp tục tăng theo bin.
- 2. `deposit_type` — Liên quan thống kê rõ đến hủy; *Non Refund* gắn với tỷ lệ hủy cực cao nhưng cần phân tích nhân quả thêm.
- 3. `market_segment` — Ảnh hưởng mạnh nhất trong các biến phân loại; **Online TA** là nguồn rủi ro hủy chính, **Corporate** tương đối ổn định.
- 4. **Mô hình đa biến** xác nhận cả ba biến vẫn có ý nghĩa (hoặc đóng góp) khi kiểm soát lẫn nhau.

Khuyến nghị hành động

Ưu tiên	Hành động	Cơ sở từ kiểm định
Cao	Theo dõi sát booking lead_time > 30 ngày , đặc biệt > 180 ngày	H1, H1b
Cao	Rà soát chính sách / forecast riêng cho Online TA	H3, H4
Trung bình	Phân tích sâu nhóm Non Refund (nhân quả vs gán nhãn)	H2
Trung bình	Ưu tiên giữ chỗ / giảm overbooking risk cho Corporate, Direct	H3
Thấp	Bổ sung biến (<code>distribution_channel</code> , <code>customer_type</code> , ...) vào mô hình v2	Pseudo R ² còn thấp

Hạn chế

- **Kích thước mẫu lớn** → p-value gần 0 không đồng nghĩa chênh lệch lớn về mặt kinh doanh; luôn kèm effect size.
- **Non Refund** và **Undefined** segment có thể bị confounding / sample nhỏ.
- Kiểm định mô tả **association**, không khẳng định nhân quả thuần túy.
- Logistic regression giả định quan hệ log-linear trên `lead_time` ; quan hệ thực tế có thể phi tuyến (đã phản ánh một phần qua bin ở H1b).

Tài liệu liên quan

- `02_eda_stage1_cancellation.ipynb` — EDA trực quan cancellation
- `04_correlation_analysis.ipynb` — Tương quan tổng hợp
- `02_eda_stage1_cancellation_analysis.md` — Báo cáo EDA Stage 1
- `04_correlation_analysis_is_canceled.md` — Báo cáo correlation

Tài liệu được tạo từ kết quả kiểm định trên `hotel_bookings_v5.csv` . Cập nhật lần cuối: 3/7/2026 — Hypothesis Testing (key dedup mới, 82.811 booking).