

Báo cáo mô hình dự đoán hủy phòng — Random Forest v1

Nguồn dữ liệu: hotel_bookings_v5.csv

Phạm vi: 82.811 booking | Tỷ lệ hủy phòng: 28,12% (~23.284 booking bị hủy)

Notebook tham chiếu: 06_cancellation_model_v1.ipynb

Thuật toán: RandomForestClassifier (scikit-learn)

Ngưỡng phân loại: 0,50 (mức chính)

1. Mục tiêu

Xây dựng mô hình baseline dự đoán is_cancelled chỉ từ 6 biến phân loại có sẵn tại thời điểm đặt phòng, với kiểm soát data leakage nghiêm ngặt. Mô hình phải đánh giá khả năng phân tách rõ ràng khi chia bổ sung biến số hành vi (lead time, lịch sử hủy, ...).

2. Thiết kế mô hình

2.1 Feature (6 biến phân loại)

Biến	Số mức	Mã hóa
deposit_type	3	One-Hot Encoding
market_segment	8	One-Hot Encoding
country	178 (gộp hiếm)	One-Hot, min_frequency=5
distribution_channel	5	One-Hot Encoding
customer_type	4	One-Hot Encoding
hotel	2	One-Hot Encoding

2.2 Chống data leakage

Ràng buộc	Cách thực hiện
Không dùng biến hậu quả	Loại reservation_status, reservation_status_date, revenue, Occupancy_Rate, RevPAR
Không leakage khi mã hóa	train_test_split (80/20, stratify) trước OneHotEncoder

Category hiệ	Group infrequent ch h c t train
--------------	---------------------------------

2.3 Siêu tham số Random Forest

Tham số	Giá trị
n_estimators	300
max_depth	12
min_samples_leaf	20
class_weight	balanced
random_state	42

3. Kết quả đánh giá (tập test — 16.563 booking)

3.1 Chỉ số tổng hợp

Chỉ số	Giá trị	Diễn giải
ROC-AUC (test)	0,734	Khả năng xếp hạng hay / không hay của mô hình chấp nhận được (~0,70–0,80)
CV ROC-AUC (5-fold, train)	0,733 ± 0,005	Mô hình ổn định, không overfit nhiều trên AUC
Accuracy	0,59	Đánh giá cao giả vì class thiểu 72/28
Precision — Hay	0,39	Trong số dự đoán hay, ~39% đúng
Recall — Hay	0,85	Bớt được ~85% booking thực sự hay
F1 — Hay	0,54	Cân bằng P/R cho class thiểu số còn trung bình
Precision — Không hay	0,89	Dự đoán không hay khá tin cậy
Recall — Không hay	0,49	Bớt sót ~51% booking không hay (gán nhầm sang hay)

3.2 Ma trận nhầm lẫn (ngưỡng 0,50)

	Dự đoán: Không hủy	Dự đoán: Hủy
Thực tế: Không hủy	TN = 5.851	FP = 6.055
Thực tế: Hủy	FN = 714	TP = 3.943

Tóm tắt nhanh: Mô hình ưu tiên Recall class Hủy (chỉ bỏ sót 714/4.657 booking hủy) nhưng trade-off giá bán False Positive cao (6.055 khách không hủy bị giảm nhận hủy). Phù hợp khi mục tiêu là tránh bỏ sót rủi ro hủy (ví dụ cảnh báo overbooking), không phù hợp nếu cần tránh “báo động giả”.

4. Feature importance (theo biến gốc)

Gini importance từ Random Forest sau One-Hot (~129 cột). Tổng hợp theo biến gốc:

Hạng	Biến gốc	Tổng importance	Mô tả đóng góp tổng thể
1	market_segment	0,354	Cao nhất — phân khúc quý khách doanh nghiệp rủi ro hủy
2	country	0,258	Quốc tịch / thị trường nguồn khách
3	customer_type	0,132	Loại khách (Transient vs Contract/Group)
4	distribution_channel	0,131	Kênh đặt (OTA vs Direct)
5	deposit_type	0,099	Chính sách cọc
6	hotel	0,027	City vs Resort — yếu hèn trong mô hình chia phân loại

Top category biến One-Hot (top 5):



Feature (sau OHE)	Importance
market_segment_Online TA	0,184
country_PRT	0,151
market_segment_Offline TA/T0	0,102

distribution_channel_TA/T0	0,072
customer_type_Transient	0,067

Nhận xét: Online TA và khách B2B (PRT) là hai tín hiệu mạnh nhất; kết quả khớp EDA/hypothesis testing (Online TA tỷ lệ cao, PRT là thị trường lớn với tỷ lệ tỷ lệ cao).



5. Trắc quan hóa & đánh giá biểu đồ

5.1 Confusion Matrix



- **Mức ích:** Tỷ lệ TN/TP/FP/FN trên test.
- **Đánh giá:** Cho thấy rõ trade-off — Recall tỷ lệ cao nhưng FP lớn. Không nên chỉ nhìn accuracy 59%.


5.2 ROC Curve



- **Mức ích:** Cho thấy rõ năng phân tách giữa hai nhóm; AUC = 0,734.


- **Ánh giá:** Mô hình v_đ ngẫu nhiên (0,5) rõ r_đ nh_đng ch_đa m_đnh t_đri_đn khai production ch_đ v_đi bi_đn phân lo_đi. ROC ph_đn ánh ranking t_đt h_đn là calibration xác su_đt tuy_đt t_đi.

5.3 Prediction Probability Distribution (Histogram + KDE)



- **Mục đích:** So sánh phân ph_đi P(h_đy) gi_đa booking th_đc s_đ h_đy vs không h_đy.
- **Quy c_đ màu:** teal = Không h_đy · orange = H_đy · Ng_đng t_đ nét = ng_đng 0,50.
- **Ánh giá:** Hai phân ph_đi ch_đng l_đn á_đng k_đ quanh 0,3–0,6 → khó tách l_đp hoàn h_đo; phù h_đp v_đi AUC ~0,73. Booking h_đy có xu h_đng P(h_đy) cao h_đn nh_đng v_đn nhi_đu overlap.

5.4 Feature Importance (bar chart top 20)



- **Mục đích:** Xác định category / biến gốc ảnh hưởng nhiều nhất tới quy tắc phân cây.
- **Ánh giá:** Hữu ích cho **diễn giải kinh doanh** (tập trung OTA, segment, thị trường PRT); không ảnh hưởng nhà nhân qu.

6. Kết luận & hạn chế

Ưu điểm

1. Pipeline sạch, kiểm soát leakage đúng quy trình ML.
2. Recall class H (85%) và $ng_{0,5}$ — hữu ích cho cảnh báo sớm.
3. `market_segment` và `country` là hai tríc phân loii quan trọng nhất.

Hạn chế

1. **Thiếu biến số** (`lead_time`, `total_of_special_requests`, ...) → AUC chỉ ~0,73.
2. **Precision thấp** cho class H → nhiều báo động giả.
3. Chỉ dùng biến phân loii → không nắm được hành vi bất thường xa / cam kết bí mật.

Khuyến nghị

- Dùng v1 làm **baseline phân lo**; chuyển sang **v1.1** khi c AUC và gíi thích a chi u h.
- Kt h p v i [05 hypothesis testing is canceled.md](#) và [04 correlation analysis is canceled.md](#) i chi u association vs prediction.

7. Tài li u liên quan

Tài li u	N i dung
06_cancellation_model_v1.ipynb	Notebook y
07_cancellation_model_v1_1.md	Mô hình m r ng + segment analysis
Guide - Cách doc chi so thong ke.md	Cách c Accuracy, F1, ROC-AUC