

Báo cáo mô hình dự đoán hủy phòng — Random Forest v1

Nguồn dữ liệu: hotel_bookings_v5.csv

Phạm vi: 82.811 booking | Tỷ lệ hủy tổng thể: **28,12%** (~23.284 booking bị hủy)

Notebook tham chiếu: 06_cancellation_model_v1.ipynb

Thuật toán: RandomForestClassifier (scikit-learn)

Ngưỡng phân loại: 0,50 (mặc định)

1. Mục tiêu

Xây dựng mô hình **baseline** dự đoán `is_canceled` chỉ từ **6 biến phân loại** có sẵn tại thời điểm đặt phòng, với kiểm soát **data leakage** nghiêm ngặt. Mô hình phục vụ đánh giá khả năng phân tách rủi ro hủy khi chưa bổ sung biến số hành vi (lead time, lịch sử hủy, ...).

2. Thiết kế mô hình

2.1 Feature (6 biến phân loại)

Biến	Số mức	Mã hóa
deposit_type	3	One-Hot Encoding
market_segment	8	One-Hot Encoding
country	178 (gộp hiếm)	One-Hot, min_frequency=5
distribution_channel	5	One-Hot Encoding
customer_type	4	One-Hot Encoding
hotel	2	One-Hot Encoding

2.2 Chống data leakage

Ràng buộc	Cách thực hiện
Không dùng biến hậu quả	Loại reservation_status , reservation_status_date , revenue , Occupancy_Rate , RevPAR
Không leakage khi mã hóa	train_test_split (80/20, stratify) trước OneHotEncoder
Category hiếm	Gộp infrequent chỉ học từ train

2.3 Siêu tham số Random Forest

Tham số	Giá trị
n_estimators	300
max_depth	12
min_samples_leaf	20
class_weight	balanced
random_state	42

3. Kết quả đánh giá (tập test — 16.563 booking)

3.1 Chỉ số tổng hợp

Chỉ số	Giá trị	Diễn giải
ROC-AUC (test)	0,734	Khả năng xếp hạng hủy / không hủy ở mức chấp nhận được (~0,70–0,80)
CV ROC-AUC (5-fold, train)	0,733 ± 0,005	Ổn định, không overfit mạnh trên AUC
Accuracy	0,59	Dễ đánh giá cao giả vì class lệch 72/28
Precision — Hủy	0,39	Trong số dự đoán hủy, ~39% đúng
Recall — Hủy	0,85	Bắt được ~85% booking thực sự hủy
F1 — Hủy	0,54	Cân bằng P/R cho class thiểu số còn trung bình
Precision — Không hủy	0,89	Dự đoán không hủy khá tin cậy
Recall — Không hủy	0,49	Bỏ sót ~51% booking không hủy (gán nhầm sang hủy)

3.2 Ma trận nhầm lẫn (ngưỡng 0,50)

	Dự đoán: Không hủy	Dự đoán: Hủy
Thực tế: Không hủy	TN = 5.851	FP = 6.055
Thực tế: Hủy	FN = 714	TP = 3.943

Độc nhanh: Mô hình **ưu tiên Recall class Hủy** (chỉ bỏ sót 714/4.657 booking hủy) nhưng trả giá bằng **False Positive cao** (6.055 khách không hủy bị gán nhãn hủy). Phù hợp khi mục tiêu là **tránh bỏ sót rủi ro hủy** (ví dụ cảnh báo overbooking), không phù hợp nếu cần tránh “báo động giả”.

4. Feature importance (theo biến gốc)

Gini importance từ Random Forest sau One-Hot (~129 cột). Tổng hợp theo biến gốc:

Hạng	Biến gốc	Tổng importance	Đóng góp tương đối
1	market_segment	0,354	Cao nhất — phân khúc quyết định mạnh rủi ro hủy

Hạng	Biến gốc	Tổng importance	Đóng góp tương đối
2	country	0,258	Quốc tịch / thị trường nguồn khách
3	customer_type	0,132	Loại khách (Transient vs Contract/Group)
4	distribution_channel	0,131	Kênh đặt (OTA vs Direct)
5	deposit_type	0,099	Chính sách cọc
6	hotel	0,027	City vs Resort — yếu hơn trong mô hình chỉ phân loại



Top category đơn lẻ (top 5):

Feature (sau OHE)	Importance
market_segment_Online TA	0,184
country_PRT	0,151
market_segment_Offline TA/TO	0,102
distribution_channel_TA/TO	0,072
customer_type_Transient	0,067

Nhận xét: Online TA và khách Bồ Đào Nha (PRT) là hai tín hiệu mạnh nhất; kết quả khớp EDA/hypothesis testing (Online TA hủy cao, PRT là thị trường lớn với tỷ lệ hủy cao).



5. Trục quan hóa & đánh giá biểu đồ

5.1 Confusion Matrix





- **Mục đích:** Đếm TN/TP/FP/FN trên test.
- **Đánh giá:** Cho thấy rõ trade-off — Recall hủy cao nhưng FP lớn. Không nên chỉ nhìn accuracy 59%.

5.2 ROC Curve




- **Mục đích:** Đo khả năng phân tách ở mọi ngưỡng; AUC = 0,734.
- **Đánh giá:** Mô hình vượt ngẫu nhiên (0,5) rõ rệt nhưng **chưa đủ mạnh** để triển khai production chỉ với biến phân loại. Đường ROC phản ánh ranking tốt hơn là calibration xác suất tuyệt đối.

5.3 Prediction Probability Distribution (Histogram + KDE)



- **Mục đích:** So sánh phân phối $P(\text{hủy})$ giữa booking thực sự hủy vs không hủy.
- **Quy ước màu:** teal = Không hủy · orange = Hủy · đường đứt nét = ngưỡng 0,50.
- **Đánh giá:** Hai phân phối **chồng lấn đáng kể** quanh 0,3–0,6 → khó tách lớp hoàn hảo; phù hợp với AUC ~0,73. Booking hủy có xu hướng $P(\text{hủy})$ cao hơn nhưng vẫn nhiều overlap.

5.4 Feature Importance (bar chart top 20)



- **Mục đích:** Xác định category / biến gốc ảnh hưởng nhiều nhất tới quyết định cây.
- **Đánh giá:** Hữu ích cho **diễn giải kinh doanh** (tập trung OTA, segment, thị trường PRT); không đồng nghĩa nhân quả.

6. Kết luận & hạn chế

Điểm mạnh

1. Pipeline sạch, kiểm soát leakage đúng quy trình ML.
2. Recall class Hủy cao (85%) với ngưỡng 0,5 — hữu ích cho cảnh báo sớm.
3. `market_segment` và `country` là hai trục phân loại quan trọng nhất.

Hạn chế

1. **Thiếu biến số** (`lead_time`, `total_of_special_requests`, ...) → AUC chỉ ~0,73.
2. **Precision thấp** cho class Hủy → nhiều báo động giả.
3. Chỉ dùng biến phân loại → không nắm được hành vi đặt trước xa / cam kết đặc biệt.

Khuyến nghị

- Dùng v1 làm **baseline phân loại**; chuyển sang **v1.1** khi cần AUC và giải thích đa chiều hơn.

- Kết hợp với [05 hypothesis testing is canceled.md](#) và [04 correlation analysis is canceled.md](#) để đối chiếu association vs prediction.

7. Tài liệu liên quan

Tài liệu	Nội dung
06_cancellation_model_v1.ipynb	Notebook đầy đủ
07_cancellation_model_v1_1.md	Mô hình mở rộng + segment analysis
Guide - Cách đọc chỉ số thống kê.md	Cách đọc Accuracy, F1, ROC-AUC