

Báo cáo mô hình dự đoán tỷ lệ phòng — Random Forest

v1.1

Ngũn d liu: hotel_bookings_v5.csv

Phím vi: 82.811 booking | **Tổng huy tng th:** **28,12%** (~23.284 booking b huy)

Notebook tham chi: 07_cancellation_model_v1_1.ipynb

Thuật toán: RandomForestClassifier (scikit-learn)

Nguyên phân loại: 0,35 ($P(h_{ij}) \geq 0,35 \rightarrow$ đoán H_{ij})

1. Mục tiêu & khác biệt so với v1

v1.1 m² r²ing baseline v1 b²ing:

1. **3 biến số:** lead_time, total_of_special_requests, previous_cancellations
2. **Nguy cơ 0,35** thay vì 0,50 — **hàng không càng tăng thì nguy cơ booking có nguy cơ hủy**

Tiêu chí	v1	v1.1
S _{new} feature	6 (phân lo _{new} i)	9 (6 phân lo _{new} i + 3 s _{new})
Ng _{new} ng	0,50	0,35
ROC-AUC (test)	0,734	0,831
Recall — H _{new} y @ ng _{new} ng chính	0,85 @ 0,50	0,94 @ 0,35

2. Thiết kế mô hình

2.1 Feature (9 bin)

Biến	Kiểu	Xử lý
deposit_type, market_segment, country, distribution_channel, customer_type, hotel	Phân loại	One-Hot Encoding
lead_time	Số nguyên	Passthrough
total_of_special_requests	Số nguyên	Passthrough
previous_cancellations	Số nguyên	Passthrough

ColumnTransformer: nhánh cat (One-Hot, min_frequency=5) + nhánh num (passthrough). Random Forest không cần chuẩn hóa scale.

2.2 Chống data leakage

Giữ nguyên nguyên tắc v1: không nhập reservation_status, revenue, Occupancy_Rate, RevPAR; split trước fit encoder; category hidden học từ train.

Lưu ý điểm gì: previous_cancellations là lịch s khách (có thể thời điểm đó), không phải leakage của booking hiện tại. lead_time và total_of_special_requests đều biết khi đặt phòng.

2.3 Ngưỡng 0,35

```
y_pred = 1 nếu P(hay) >= 0.35
```

Ý nghĩa kinh doanh: Chấp nhận gain nhận “có nguy cơ hay” sớm hơn → tăng Recall, giảm FN (bớt booking sai hay), tức là tăng FP so với ngưỡng cao hơn.

3. Kết quả đánh giá (tập test — 16.563 booking)

3.1 Chọn số tăng hợp @ ngưỡng 0,35

Chỉ số	Giá trị	Điểm gì
ROC-AUC (test)	0,831	Tốt — cải thiện ~+0,10 so với v1
CV ROC-AUC (5-fold)	0,829 ± 0,004	Ổn định, generalize tốt
Accuracy	0,60	Vẫn thấp do class lệch; không dùng làm metric chính
Precision — Hay	0,41	~41% dự đoán hay là đúng
Recall — Hay	0,94	Bớt ~94% booking thực sai hay
F1 — Hay	0,57	@ 0,35
Precision — Không hay	0,95	Rất cao khi dự đoán không hay
Recall — Không hay	0,47	~53% booking không hay bị gán nhầm “hay”

3.2 So sánh ngưỡng 0,35 vs 0,50 (cùng mô hình v1.1)

Metric (class Hay)	@ 0,50	@ 0,35
F1	0,600	0,570

Recall (tỷ lệ CM)	0,82	0,94
FN (bớt số huy)	~822	~273

Kết luận ngắn gọn: 0,35 không tối ưu F1 nhưng giảm mạnh FN (273 vs 822) — phù hợp chiến lược ưu tiên không bớt số huy (overbooking / inventory protection). Nếu cần cân bằng P/R, cân nhắc 0,45–0,50.

3.3 Ma trận nhầm lẫn @ 0,35

	Dự đoán: Không huy	Dự đoán: Huy
Thực tế: Không huy	TN = 5.552	FP = 6.354
Thực tế: Huy	FN = 273	TP = 4.384

4. Feature importance analysis

4.1 Top 20 feature (sau tỉ lệ x lý)

Hạng	Feature	Importance	Biên giải
1	lead_time	0,211	lead_time
2	market_segment_Online TA	0,132	market_segment
3	country_PRT	0,110	country
4	total_of_special_requests	0,100	total_of_special_requests
5	market_segment_Offline TA/TO	0,073	market_segment
6	customer_type_Transient	0,046	customer_type
7	distribution_channel_TA/TO	0,045	distribution_channel
8	customer_type_Transient-Party	0,032	customer_type
9	previous_cancellations	0,030	previous_cancellations
10	deposit_type_No Deposit	0,028	deposit_type

Nhận xét: `lead_time` vọt lên #1 sau khi bổ sung biến `s` — khớp hypothesis (Mann-Whitney, $r \approx 0,30$). `total_of_special_requests` top 4 (nhieu yêu cầu → ít hủy). `previous_cancellations` có vai trò nhỏ hơn những biến vào top 10.

4.2 Gom nhóm theo biến gini (tính Gini importance)

Hạng	Biến gini	Tính importance	% trong tổng	Đánh giá
1	<code>market_segment</code>	0,248	24,8%	Vấn quan trọng nhất trong nhóm phân loại
2	<code>lead_time</code>	0,211	21,1%	Lever hành vi mạnh nhất — ít trễ xa → rủi ro cao
3	<code>country</code>	0,175	17,5%	Thị trường nguồn (PRT nổi bật)
4	<code>total_of_special_requests</code>	0,100	10,0%	Cam kết / nhu cầu đặc thù → giảm rủi ro
5	<code>customer_type</code>	0,088	8,8%	Transient rủi ro hơn Contract/Group
6	<code>distribution_channel</code>	0,076	7,6%	OTA (TA/TO) vs Direct
7	<code>deposit_type</code>	0,055	5,5%	Non Refund đặc biệt — thu (xem segment)
8	<code>previous_cancellations</code>	0,030	3,0%	Lịch sử hủy — tín hiệu phụ
9	<code>hotel</code>	0,018	1,8%	City Hotel hủy cao hơn Resort

Sơ đồ v1: `lead_time` chiếm ~21% importance (trước đó không có); `market_segment` giảm tầm trung tầm 24% chỉ đứng vọt #1; `country` vọt top 3.

5. Segment cancellation rate

Tỷ lệ hủy thực tế (`is_canceled`) theo từng nhóm — chỉ để vớt vớt feature importance và hành trình quản lý doanh thu.

5.1 `lead_time` (ngày đặt trước)

Nhóm	Số booking	Tỷ lệ hủy
0–30 ngày	33.039	16,8%
31–60	12.776	32,2%
61–90	8.967	33,2%
91–180	17.355	36,0%
> 180	10.674	41,7%

Đánh giá: Gradient rõ — lead time dài góp ~2,5 lần rủi ro so với booking trong 30 ngày. Khớp importance #2 của mô hình.

5.2 market_segment

Segment	n	Tỷ lệ hủy
Online TA	50.391	35,5%
Groups	3.690	31,2%
Offline TA/TO	12.860	15,1%
Direct	11.351	14,9%
Corporate	3.678	12,8%
Complementary	619	13,1%

Đánh giá: Online TA là nguồn rủi ro chính (~36% trên mức TB 28%). Corporate/Direct nên phân bổ — phù hợp chính sách check/confirmation khác nhau theo segment.

5.3 distribution_channel

Kênh	n	Tỷ lệ hủy
TA/TO	65.956	31,5%
GDS	172	19,8%
Direct	12.291	15,1%
Corporate	4.387	13,6%

5.4 customer_type

Loại khách	n	Tỉ lệ %
Transient	69.939	30,4%
Transient-Party	9.294	15,8%
Contract	3.068	16,5%
Group	510	10,6%

5.5 hotel

Khách sạn	n	Tỉ lệ %
City Hotel	50.686	30,7%
Resort Hotel	32.125	24,1%

5.6 deposit_type

Loại cọc	n	Tỉ lệ %
No Deposit	81.767	27,3%
Non Refund	963	95,0%
Refundable	81	28,4%

Cảnh báo: Non Refund ~95% tỷ lệ — có thể phản ánh chính sách đặc biệt / gắn nhãn là hành vi khách tiêu dùng; cần thận trọng khi diễn giải nhân quả.

5.7 total_of_special_requests

Số yêu cầu đặc biệt	n	Tỉ lệ %
0	40.983	34,3%
1	27.860	22,9%
2	11.384	21,4%
3+	2.584	16,4%

Ảnh hưởng: Càng nhiều special request → càng cam kết → tỷ lệ giảm. Họ thường khuyến khích upsell / personalization có thể giảm rủi ro.

5.8 previous_cancellations

Lịch sử history track	n	Tỷ lệ history
0	81.255	27,4%
1	1.303	76,4%
2+	253	22,9%

Giải thích: Khách hàng history đúng 1 lần có tỷ lệ history rất cao; nhóm 2+ sample nhỏ (253) — không nên nhìn thống kê.



5.9 country (top 10 theo volume)

Quốc gia	n	Tỷ lệ history
PRT	25.299	36,8%
BRA	1.936	36,8%
ITA	2.900	36,1%
ESP	6.973	26,2%
GBR	9.921	19,6%
FRA	8.464	20,1%

Giải thích: PRT (Bồ Đào Nha) — thị trường nổi bật nhất — history cao hơn TB; GBR/FRA tổng cộng chỉ nhìn.



6. Trắc quan hóa & Giải thích biểu đồ

6.1 Confusion Matrix (@ 0,35)




- **Đánh giá:** Cho thấy chỉ số mất mát tổng cộng thấp — FN chỉ 273 nhưng FP 6.354. Phù hợp mức tiêu “bớt hủy hết booking sớm hơn”, không phù hợp nếu muốn giảm thiểu báo động tụt chi phí can thiệp.

6.2 ROC Curve (AUC = 0,831)




- **Đánh giá:** Chỉ số mất mát rõ ràng thấp (0,734). Mô hình xếp hạng rủi ro tốt; ngưỡng 0,35 là điểm cắt trên đường ROC, không làm thay đổi AUC.
- **Ghi ý:** Kết hợp ROC với Precision-Recall curve nếu cần tối ưu ngưỡng theo chi phí FP/FN.

6.3 Prediction Probability Distribution (Histogram + KDE)



- **Quy tắc màu:** teal = Không hủy · orange = Hủy · Ngưỡng nét = ngưỡng 0,35.
- **Đánh giá:** Hai phân phối tách biệt tốt hơn v1 (AUC cao hơn). Vẫn có overlap vùng 0,25–0,55 — bình thường với dữ liệu hành vi. Median P(hủy) nhóm thực sự hủy cao hơn nhóm không hủy (xem notebook).
- **Ngưỡng 0,35:** Nằm trong vùng overlap → tăng Recall nhưng kéo theo nhiều FP từ phân phối “Không hủy”.

6.4 Feature Importance (bar chart top 20 + bảng gom nhóm)



- **Ánh giá:** Xác nhđn `lead_time` và `market_segment` là hai trđc chính; hđ trđ đđu tiên can thiđp (chđnh sách lead time, OTA segment, incentive special requests).

7. Kđt luđn tđng thđ

đđđm đđnh v1.1

1. **ROC-AUC 0,831** — mđc tđt, sđn sàng cho giai đđđn pilot / scoring đđđ bđ.
2. Bđ sung biđn sđ giúp mô hình **đđđđ thđch đđđđđ** và khđp EDA (lead time, special requests).
3. Ngđđđng **0,35** phù hđp bài toán **đđđm bđ sốt hđy** (Recall 94%).
4. Segment analysis chđ ra **Online TA, City Hotel, PRT, lead time > 180 ngày** là nhóm đđu tiên can thiđp.

Hđn chđ & rđđ ro

1. **Precision thđp** (~41%) @ 0,35 — nhđđu booking không hđy bđ flag.
2. `deposit_type_Non Refund` và segment cđc nhđ (Undefined, 2+ cancellations) — đđđ nhđđu.
3. Random Forest importance **không phđđ causal** — cđn đđđđ chỉđđu A/B hođc chđnh sách trđđđđđ khi trđđđn khai.
4. Chđđđ tune hyperparameter / chđđđ calibration xác suđđt (Platt / isotonic).

Khuyđđn nghđđ hành đđđng

đđu tiên	Hành đđđng	Segment / feature liên quan
1	Chđnh sách cđđđ / xác nhđđn chđđt hđđn cho Online TA + lead time > 90 ngày	<code>market_segment</code> , <code>lead_time</code>
2	Theo đđđđ riêng khách PRT và previous_cancellations = 1	<code>country</code> , <code>lđch sđđ</code>
3	Khuyđđn khđch special requests / bundle đđđđđ vđđ	<code>total_of_special_requests</code>
4	Pilot scoring: $P(hđđy) \geq 0,35 \rightarrow$ alert RM; đđđ FP cost thđđđ tđđ	Ngđđđng v1.1

8. Tài liđđu liên quan

Tài liđđu	Nđđđđ đđđđ
<code>07_cancellation_model_v1_1.ipynb</code>	Notebook đđđđđ đđđđđ
06_cancellation_model_v1.md	Baseline phân lođđđđđ
05_hypothesis_testing_is_canceled.md	Kđđđđ đđđđđnh <code>lead_time</code> , <code>deposit</code> , <code>segment</code>

[04_correlation_analysis_is_canceled.md](#)

Tier feature & leakage