

Báo cáo mô hình dự đoán hủy phòng — Random Forest v1.2

Nguồn dữ liệu: hotel_bookings_v5.csv

Phạm vi: 82.811 booking | Tỷ lệ hủy phòng: 28,12% (~23.284 booking bị hủy)

Notebook tham chiếu: 08_cancellation_model_v1_2.ipynb

Thuật toán: RandomForestClassifier (scikit-learn) + giải thích SHAP (TreeExplainer)

Ngưỡng phân loại: 0,35 ($P(hủy) \geq 0,35 \rightarrow$ dự đoán Hủy)

1. Mục tiêu & khác biệt so với v1.1

v1.2 kế thừa v1.1 và bổ sung **feature engineering** theo 4 nhóm biến, ứng dụng dùng **SHAP** để giải thích đóng góp của từng biến mới vào quyết định dự đoán.

Tiêu chí	v1.1	v1.2
Số feature gốc	9 (6 phân loại + 3 số)	16 (6 phân loại + 10 số)
Feature engineering	Không	9 biến engineered (4 nhóm)
Biến lịch sử	previous_cancellations (thô)	history_cancel_rate (tỉ lệ)
Giải thích mô hình	Feature importance (Gini)	Gini + SHAP (local & global)
Ngưỡng	0,35	0,35 (giữ nguyên)
ROC-AUC (test)	0,831	0,840
Recall — Hủy @ 0,35	0,94	0,94

Cải thiện chính: ROC-AUC tăng **+0,009** (~+1,1%) so v1.1; 4 biến engineered lọt **top 20** Gini importance; SHAP xác nhận lead_time_per_night là biến engineered đóng góp mạnh nhất.

2. Thiết kế mô hình

2.1 Feature engineering (4 nhóm)

Nhóm 1 — Mục cam kết tài chính (Financial Commitment)

Biến	Công thức	Ghi chú
total_guests	adults + children + babies	Clip tối thiểu = 1
price_per_person	adr / total_guests	Giá trên mỗi khách

is_family	1 nếu children > 0 hoặc babies > 0	Nhóm gia đình
-----------	------------------------------------	---------------

Nhóm 2 — Cấu trúc chuyến đi (Trip Structure)

Biến	Công thức	Ghi chú
total_nights	stays_in_weekend_nights + stays_in_week_nights	Tổng đêm lưu trú
lead_time_per_night	lead_time / total_nights	Clip máu s ≤ 1

Nhóm 3 — Lịch sử và uy tín (Trust & History)

Biến	Công thức	Ghi chú
history_cancel_rate	previous_cancellations / (previous_cancellations + previous_bookings_not_canceled)	= 0 nếu chưa có lịch sử

Nhóm 4 — Lịch & mùa (Calendar & Seasonality)

Biến	Công thức	Ghi chú
is_weekend_only	1 nếu weekend_nights > 0 và week_nights == 0	Chỉ cuối tuần
arrival_month_mapped	Tháng → số 1-12 (Jan→1 ... Dec→12)	Mùa vụ

2.2 Feature đưa vào mô hình (16 biến)

Biến	Kiểu	Xử lý
deposit_type, market_segment, country, distribution_channel, customer_type, hotel	Phân loại	One-Hot Encoding
lead_time, total_of_special_requests	Số (v1.1)	Passthrough
8 biến engineered trên	Số	Passthrough

ColumnTransformer: nhánh cat (One-Hot, min_frequency=5) + nhánh num (passthrough). Sau encoding: **139 cột** đưa vào Random Forest.

Hyperparameter RF (giới v1.1): n_estimators=300, max_depth=12, min_samples_leaf=20, class_weight='balanced'.

2.3 Chẩn data leakage

- 1. Không nhập reservation_status, revenue, Occupancy_Rate, RevPAR, ...
- 2. Feature engineering chỉ dùng thông tin có thời điểm đặt phòng (adr, lead_time, lịch số khách, ...).
- 3. train_test_split trước khi build encoder.
- 4. OneHotEncoder chỉ fit trên tập train (qua Pipeline).

Lưu ý: history_cancel_rate tăng giúp lịch số quá khứ — giúp lịch vì biết khi khách đặt; không phải leakage của booking hiện tại.

2.4 Ngưỡng 0,35

```
y_pred = 1 nếu P(hay) >= 0.35
```

Giống ngưỡng v1.1 chỉ so sánh công bằng: ưu tiên Recall (không bỏ sót booking số hay), chấp nhận tăng False Positive.

3. Kết quả đánh giá (tập test — 16.563 booking)

3.1 Chỉ số tăng giúp @ ngưỡng 0,35

Chỉ số	Giá trị	Diễn giải
ROC-AUC (test)	0,840	Tốt — cải thiện +0,009 so v1.1
CV ROC-AUC (5-fold)	0,838 ± 0,004	Ổn định, generalize tốt
Accuracy	0,62	Không dùng làm metric chính (class lệch)
Precision — Hay	0,42	~42% dự đoán hay là đúng
Recall — Hay	0,94	Bớt ~94% booking thực số hay
F1 — Hay	0,58	@ 0,35
Precision — Không hay	0,95	Rất cao khi dự đoán không hay
Recall — Không hay	0,49	~51% booking không hay bị gán nhầm “hay”

3.2 So sánh ngưỡng 0,35 vs 0,50 (cùng mô hình v1.2)

Metric (class Hay)	@ 0,50	@ 0,35
F1	0,613	0,581
Recall	0,83	0,94

FN (bị sót hàng)	~812	~289
------------------	------	------

Kết luận ngắn: 0,35 giảm FN từ ~812 xuống 289 (-64%) — phù hợp chiến lược inventory protection; 0,50 tăng độ ưu tiên F1 / Precision.

3.3 Ma trận nhầm lẫn @ 0,35

	Dự đoán: Không hàng	Dự đoán: Hàng
Thực tế: Không hàng	TN = 5.893	FP = 6.013
Thực tế: Hàng	FN = 289	TP = 4.368

3.4 Phân phối xác suất dự đoán (test)

Nhãn thực tế	n	Mean P(hàng)	Median P(hàng)	Std
Không hàng	11.906	0,384	0,354	0,173
Hàng	4.657	0,612	0,627	0,143

Hai phân phối tách biệt rõ hơn v1.1 (AUC cao hơn). Giảm 0,35 nằm trong vùng overlap → tăng Recall, kéo theo nhu cầu FP.

4. Feature importance (Gini)

4.1 Top 20 feature (sau tiền xử lý)

Hạng	Feature	Importance	Biên giới / nhóm
1	lead_time	0,141	lead_time
2	country_PRT	0,113	country
3	market_segment_Online TA	0,111	market_segment
4	lead_time_per_night	0,108	Trip Structure
5	total_of_special_requests	0,085	total_of_special_requests

6	market_segment_Offline TA/TO	0,056	market_segment
7	customer_type_Transient	0,042	customer_type
8	history_cancel_rate	0,033	Trust & History
9	distribution_channel_TA/TO	0,029	distribution_channel
10	customer_type_Transient-Party	0,028	customer_type
11	price_per_person	0,028	Financial Commitment
12	deposit_type_Non Refund	0,028	deposit_type
13	total_nights	0,027	Trip Structure
14	distribution_channel_Direct	0,020	distribution_channel
15	deposit_type_No Deposit	0,019	deposit_type
16	market_segment_Direct	0,017	market_segment
17	country_GBR	0,016	country
18	total_guests	0,013	Financial Commitment
19	country_FRA	0,010	country
20	arrival_month_mapped	0,008	Calendar & Seasonality

Nhấn xét: 4 biến engineered trong top 20; lead_time_per_night (#4) gần sát lead_time (#1) — chuẩn hóa lead time theo độ dài chuyến đi mang tín hiệu dự báo mạnh.

4.2 Gom nhóm theo biến gốc (tính Gini importance)

Hạng	Biến / nhóm	Tính importance	Đánh giá
1	market_segment	0,195	Kênh OTA và quan trọng
2	country	0,164	Thị trường nguồn (PRT)
3	lead_time	0,141	Thời điểm xa → rủi ro cao
4	lead_time_per_night	0,108	Biến engineered mạnh nhất

5	total_of_special_requests	0,085	Cam kết / nhu cầu c
6	customer_type	0,077	Transient rời rạc
7	distribution_channel	0,054	TA/TO vs Direct
8	deposit_type	0,047	Chính sách c
9	history_cancel_rate	0,033	Lịch s h — tín hi
10	price_per_person	0,028	Cam kết tài chính
11	total_nights	0,027	Cấu trúc chuy
12	hotel	0,015	City vs Resort
13	total_guests	0,013	Quy mô nhóm khách
14	arrival_month_mapped	0,008	Mùa v — y h
15	is_family	0,003	Gia đình — y
16	is_weekend_only	0,002	Cuối tu — y nh

5. Giải thích SHAP — Built engineered

5.1 Phương pháp

Thành phần	Cài đặt
Thư viện	shap — TreeExplainer
Mô hình giải thích	RandomForestClassifier sau ColumnTransformer
Dữ liệu	Mẫu 2.000 booking ngẫu nhiên từ tập test (random_state=42)
Class giải thích	High (class 1) — SHAP đo đóng góp vào P(h)

Cách đọc SHAP:

- $SHAP > 0 \rightarrow$ y xác suất h tăng (nguy cơ cao hơn)
- $SHAP < 0 \rightarrow$ y xác suất h giảm (nguy cơ thấp hơn)
- $|SHAP|$ lớn $\rightarrow$ feature đóng góp mạnh vào quyết định cho booking c

Khác với Gini importance (trung bình toàn cục, không có dấu), SHAP cho biết hướng và mức tác động trên từng quan sát.

5.2 Mean |SHAP| — Xếp hạng biến engineered

Hạng	Biến	Mean SHAP	Mean SHAP	Nhóm	Diễn giải
1	lead_time_per_night	0,032	−0,005	Trip Structure	Góp lớn nhất; trung bình hơi kéo P(hủy) xuống
2	price_per_person	0,011	−0,002	Financial Commitment	Giá/người cao → tăng giảm rủi ro hủy
3	total_nights	0,010	−0,001	Trip Structure	Số đêm dài hơn → xu hướng giảm rủi ro
4	history_cancel_rate	0,006	−0,001	Trust & History	Lịch sử hủy cao → SHAP đóng góp nhỏ trên từng case
5	total_guests	0,004	−0,000	Financial Commitment	Nhiều khách → tác động nhỏ
6	arrival_month_mapped	0,003	−0,000	Calendar	Mùa xuân — tác động yếu
7	is_family	0,002	−0,000	Financial Commitment	Gia đình — tác động yếu
8	is_weekend_only	0,001	−0,000	Calendar	Cuối tuần — yếu nhất

5.3 Tổng hợp theo nhóm feature engineering

Nhóm	Tổng mean SHAP	Mean SHAP	Đánh giá
Trip Structure	0,042	−0,006	Nhóm engineered quan trọng nhất — chủ yếu nhất lead_time_per_night
Financial Commitment	0,017	−0,003	price_per_person là trọng tâm

Trust & History	0,006	-0,001	Mức biến động có giá trị khi lệch lệch > 0
Calendar & Seasonality	0,004	-0,000	Tín hiệu phụ so với lead time / segment

5.4 Diễn giải theo từng biến (SHAP + Gini)

lead_time_per_night (Trip Structure)

- Gini #4 toàn mô hình | SHAP #1 trong nhóm engineered
- Chuyển hóa lead_time theo số đêm giúp tách booking “tối sớm nhất” vs “tối sớm và dài”.
- Trên trung bình mức SHAP âm: lead time/đêm thấp (tối gấp, nhiều đêm) thường giảm SHAP đáng → tăng P(hay); cao → giảm P(hay).
- Hành động: Kết hợp rule lead_time_per_night cao với segment OTA để ưu tiên xác nhận / chốt.

price_per_person (Financial Commitment)

- Gini #11 | SHAP #2 engineered
- Giá trên mức khách phản ánh mức cam kết tài chính tăng; SHAP âm trung bình → giá/người cao hơn thường giảm xác suất hay.
- Hành động: Booking ADR thấp/khách + lead time dài → ưu tiên can thiệp (upsell, chốt).

total_nights (Trip Structure)

- Gini #13 | SHAP #3 engineered
- Chuyển dài hơn → xu hướng cam kết cao hơn (SHAP âm trung bình).
- Bổ sung cho lead_time: không chỉ “tối trước bao lâu” mà “bao lâu”.

history_cancel_rate (Trust & History)

- Gini #8 | SHAP #4 engineered
- Thay previous_cancellations thông tin giúp mô hình so sánh công bằng giữa khách ít/nhiều lịch s.
- Khi history_cancel_rate > 0 (mức biến động ≈ 1), SHAP đáng m → tỷ lệ P(hay) lên rõ rệt trên tổng booking.
- Hành động: Flag riêng khách có tỷ lệ hủy quá 50%.


total_guests, is_family (Financial Commitment)

- Tác động SHAP nhỏ; is_family yếu nhất trong nhóm Financial.
- Gia đình (có trẻ) không tạo tín hiệu hay mạnh mẽ các tăng trưởng — có thể do tương quan với segment / lead time.


arrival_month_mapped, is_weekend_only (Calendar)

- SHAP và Gini đều thấp nhất trong các biến engineered.
- Mùa vụ và “chỉ cuối tuần” có tín hiệu nhưng bị lu mờ bởi market_segment, lead_time, country.

5.5 Biểu đồ SHAP trong notebook




Biểu đồ	Nội dung
Bar SHAP theo biến & nhóm	So sánh độ lớn đóng góp trung bình
Beeswarm	Phân bố SHAP theo giá trị feature (màu = cao/thấp)







| Dependence (top 3) | Quan hệ phi tuyến: lead_time_per_night, price_per_person, total_nights |

Nguy cơ thấp — $P(\text{hủy})=0.096$, thực tế=Không hủy
 $f(x) = 0.096$




Nguy cơ cao — P(hủy)=0.947, thực tế=Hủy


$f(x) = 0.947$



| Waterfall | Gi¶i thích t¶ng booking nguy c¶ cao / th¶p (toàn feature) |





| Bar engineered | Ch 8 biến m trong 2 ví d biến hình |





6. Trắc quan hóa & đánh giá biểu

6.1 Confusion Matrix (@ 0,35)





FN = 289 (giảm so v1.1 ~273–289 tùy run), FP = 6.013. Chiến lược ngưỡng thấp — phù hợp không bỏ sót hủy, không phù hợp nếu muốn cảnh báo tén chi phí cao.

6.2 ROC Curve (AUC = 0,840)




Cải thiện so v1.1 (0,831). Mô hình xếp hạng rủi ro tốt; ngưỡng 0,35 là điểm cắt kinh doanh, không ảnh hưởng AUC.

6.3 Prediction Probability Distribution



Median P(h_{xy}): Không h_{xy} **0,35** · H_{xy} **0,63** — tách l_p t_lt. Overlap vùng 0,25–0,55 v_n t_nn t_li (bình th_ll_lng v_li d_l li_lu hành vi).

6.4 Feature Importance vs SHAP



Góc nhìn	Gini importance	SHAP
Phạm vi	Toàn cục, không dῡu	Local + trung bình có dῡu

Biến engineered nổi bật	lead_time_per_night, history_cancel_rate, price_per_person	Cùng thời; SHAP bổ sung hướng tác động
Khuyến nghị	Chọn feature, ranking	Giới thích quy trình, audit tăng booking

7. Kết luận tổng thể

Hiệu suất mô hình v1.2

- ROC-AUC 0,840** — cải thiện so v1.1, sẵn sàng pilot scoring nổi bật.
- Feature engineering có giá trị:** lead_time_per_night vào top 4 toàn mô hình; 4/8 biến engineered trong top 20 Gini.
- SHAP** xác nhận và bổ sung hướng tác động — các biến hữu ích cho history_cancel_rate và price_per_person về mức tăng booking.
- Ngưỡng 0,35 giữ **Recall 94%**, FN ≈ 289.

Hạn chế & rủi ro

- Precision thấp** (~42%) @ 0,35 — nhiều booking không hợp lệ bị flag.
- Biến Calendar (is_weekend_only, arrival_month_mapped) **không góp ý** — có thể thiếu encoding mùa (Spring/Summer/...) hoặc biến giả định.
- SHAP trên Random Forest + One-Hot **tính toán** — production nên cache explainer hoặc giảm mô.
- Gini / SHAP **không phải nhân quả** — cần A/B kiểm tra khi đổi chính sách giá hoặc các.

Khuyến nghị hành động

Mục tiêu	Hành động	Feature / SHAP liên quan
1	Rule kết hợp: Online TA + lead_time_per_night cao → xác nhận chốt	Trip Structure, segment
2	Flag khách history_cancel_rate > 0 (các biến ≈ 1)	Trust & History
3	Booking price_per_person thấp + lead time dài → ưu tiên các / upsell	Financial Commitment
4	Pilot: P(hợp) >= 0,35 + giới thích SHAP top-3 feature cho RM	Notebook mức 7

5	Th■ v1.3: seasonal encoding, interaction (lead_time_per_night × market_segment)	Calendar, Trip
---	--	----------------

8. Tài li■u liên quan

Tài li■u	N■i dung
08_cancellation_model_v1_2.ipynb	Notebook ■■■y ■■■ (hu■n luy■n + SHAP)
07_cancellation_model_v1_1.md	Phiên b■n tr■■c (9 feature)
06_cancellation_model_v1.md	Baseline phân lo■i
05_hypothesis_testing_is_canceled.md	Ki■m ■■■nh lead_time, deposit, segment
04_correlation_analysis_is_canceled.md	Tier feature & leakage