

# Báo cáo mô hình dự đoán hủy phòng — LightGBM v2

**Nguồn dữ liệu:** hotel\_bookings\_v5.csv

**Phạm vi:** 82.811 booking | Tỷ lệ hủy tổng thể: **28,12%** (~23.284 booking bị hủy)

**Notebook tham chiếu:** models/Cancellation Predict Model v2/09\_cancellation\_model\_v2.ipynb

**Thuật toán:** LGBMClassifier (LightGBM) + tinh chỉnh **GridSearchCV** & **Optuna** + giải thích **SHAP** ( TreeExplainer )

**Ngưỡng phân loại:** **0,35** (  $P(\text{hủy}) \geq 0,35 \rightarrow$  dự đoán Hủy)

## 1. Mục tiêu & khác biệt so với RF v1.2

v2 kế thừa **toàn bộ feature engineering** từ v1.2 (16 biến, 4 nhóm engineered), thay thuật toán Random Forest bằng **LightGBM** và bổ sung **tinh chỉnh hyperparameter** tự động.

| Tiêu chí               | RF v1.2                    | LightGBM v2                     |
|------------------------|----------------------------|---------------------------------|
| Thuật toán             | RandomForestClassifier     | LGBMClassifier                  |
| Số feature             | 16 (6 phân loại + 10 số)   | Giữ nguyên v1.2                 |
| Feature engineering    | 9 biến engineered (4 nhóm) | Giữ nguyên                      |
| Tinh chỉnh HP          | Không (cố định)            | GridSearchCV + Optuna (mục 3b)  |
| Importance             | Gini                       | Gain (chuẩn GBDT)               |
| Ngưỡng                 | 0,35                       | <b>0,35</b> (so sánh công bằng) |
| ROC-AUC (test)         | 0,840                      | <b>0,871</b> (tuned)            |
| Recall — Hủy @ 0,35    | 0,94                       | <b>0,90</b>                     |
| Precision — Hủy @ 0,35 | 0,42                       | <b>0,49</b>                     |
| Accuracy @ 0,35        | 0,62                       | <b>0,71</b>                     |

**Cải thiện chính:** ROC-AUC tăng **+0,031** (~+3,7%) so RF v1.2; Precision Hủy tăng ~7 điểm phần trăm. Recall Hủy giảm nhẹ (0,90 vs 0,94) do trade-off khi mô hình calibrated tốt hơn — có thể bù bằng hạ ngưỡng nếu ưu tiên inventory protection.

## 2. Thiết kế mô hình

### 2.1 Feature engineering (4 nhóm — giữ nguyên v1.2)

#### Nhóm 1 — Mức độ cam kết tài chính (Financial Commitment)

| Biến         | Công thức                  | Ghi chú            |
|--------------|----------------------------|--------------------|
| total_guests | adults + children + babies | Clip tối thiểu = 1 |

| Biến             | Công thức                          | Ghi chú            |
|------------------|------------------------------------|--------------------|
| price_per_person | adr / total_guests                 | Giá trên mỗi khách |
| is_family        | 1 nếu children > 0 hoặc babies > 0 | Nhóm gia đình      |

## Nhóm 2 — Cấu trúc chuyến đi (Trip Structure)

| Biến                | Công thức                                      | Ghi chú              |
|---------------------|------------------------------------------------|----------------------|
| total_nights        | stays_in_weekend_nights + stays_in_week_nights | Tổng đêm lưu trú     |
| lead_time_per_night | lead_time / total_nights                       | Clip mẫu số $\geq 1$ |

## Nhóm 3 — Lịch sử và uy tín (Trust & History)

| Biến                | Công thức                                                                          | Ghi chú                 |
|---------------------|------------------------------------------------------------------------------------|-------------------------|
| history_cancel_rate | previous_cancellations / (previous_cancellations + previous_bookings_not_canceled) | = 0 nếu chưa có lịch sử |

## Nhóm 4 — Lịch & mùa (Calendar & Seasonality)

| Biến                 | Công thức                                                                      | Ghi chú         |
|----------------------|--------------------------------------------------------------------------------|-----------------|
| is_weekend_only      | 1 nếu weekend_nights > 0 và week_nights == 0                                   | Chỉ ở cuối tuần |
| arrival_month_mapped | Tháng đến $\rightarrow$ số 1-12 (Jan $\rightarrow$ 1 ... Dec $\rightarrow$ 12) | Mùa vụ          |

## 2.2 Feature đưa vào mô hình (16 biến)

| Biến                                                                              | Kiểu      | Xử lý            |
|-----------------------------------------------------------------------------------|-----------|------------------|
| deposit_type, market_segment, country, distribution_channel, customer_type, hotel | Phân loại | One-Hot Encoding |
| lead_time, total_of_special_requests                                              | Số (v1.1) | Passthrough      |
| 8 biến engineered ở trên                                                          | Số        | Passthrough      |

ColumnTransformer : nhánh cat (One-Hot, min\_frequency=5) + nhánh num (passthrough). Sau encoding: **139 cột** đầu vào LightGBM.

## 2.3 Hyperparameter

### Baseline (trước tune)

| Tham số           | Giá trị |
|-------------------|---------|
| n_estimators      | 300     |
| max_depth         | 12      |
| min_child_samples | 20      |

| Tham số          | Giá trị  |
|------------------|----------|
| learning_rate    | 0,05     |
| subsample        | 0,8      |
| colsample_bytree | 0,8      |
| class_weight     | balanced |

### Tinh chỉnh (mục 3b notebook)

| Phương pháp                             | Mục tiêu | CV ROC-AUC   |
|-----------------------------------------|----------|--------------|
| Baseline                                | —        | 0,862        |
| <b>GridSearchCV</b> (64 tổ hợp, 3-fold) | roc_auc  | 0,863        |
| <b>Optuna TPE</b> (35 trials, 3-fold)   | roc_auc  | <b>0,865</b> |

**Chọn:** Optuna (CV ROC-AUC cao hơn GridSearch).

### Best params (Optuna — mô hình production trong notebook)

| Tham số           | Giá trị  |
|-------------------|----------|
| n_estimators      | 250      |
| max_depth         | 15       |
| num_leaves        | 61       |
| min_child_samples | 35       |
| learning_rate     | 0,063    |
| subsample         | 0,796    |
| colsample_bytree  | 0,633    |
| reg_alpha         | 0,008    |
| reg_lambda        | 3,265    |
| class_weight      | balanced |

## 2.4 Chống data leakage

1. Không nạp reservation\_status , revenue , Occupancy\_Rate , RevPAR , ...
2. Feature engineering chỉ dùng thông tin **có tại thời điểm đặt phòng**.
3. train\_test\_split **trước** mọi bước fit encoder và tune.
4. OneHotEncoder + GridSearch/Optuna chỉ fit trên tập train (qua Pipeline ).

## 2.5 Ngưỡng 0,35

```
y_pred = 1 nếu P(hủy) >= 0.35
```

Giữ ngưỡng v1.2 để so sánh công bằng: ưu tiên **Recall**, chấp nhận tăng False Positive.

### 3. Kết quả đánh giá (tập test — 16.563 booking)

#### 3.1 So sánh Baseline vs Tuned @ ngưỡng 0,35

| Chỉ số                | Baseline LGBM | Tuned (Optuna)       | RF v1.2 (tham chiếu) |
|-----------------------|---------------|----------------------|----------------------|
| ROC-AUC (test)        | 0,867         | <b>0,871</b>         | 0,840                |
| CV ROC-AUC (5-fold)   | —             | <b>0,867 ± 0,004</b> | 0,838 ± 0,004        |
| Accuracy              | 0,698         | <b>0,710</b>         | 0,62                 |
| Precision — Hủy       | 0,480         | <b>0,492</b>         | 0,42                 |
| Recall — Hủy          | 0,905         | <b>0,899</b>         | 0,94                 |
| F1 — Hủy              | 0,627         | <b>0,636</b>         | 0,58                 |
| Precision — Không hủy | 0,94          | <b>0,94</b>          | 0,95                 |
| Recall — Không hủy    | 0,64          | <b>0,64</b>          | 0,49                 |

**Nhận xét:** Tuned cải thiện AUC (+0,005), Accuracy, Precision và F1; Recall giảm nhẹ (−0,6 điểm phần trăm) so baseline LGBM. So RF v1.2: AUC cao hơn rõ, Precision tốt hơn, Recall thấp hơn ~4 điểm phần trăm.

#### 3.2 So sánh ngưỡng 0,35 vs 0,50 (mô hình Tuned)

| Metric (class Hủy) | @ 0,50       | @ <b>0,35</b> |
|--------------------|--------------|---------------|
| F1                 | <b>0,676</b> | 0,636         |
| Recall             | ~0,79        | <b>0,90</b>   |
| FN (bỏ sót hủy)    | ~980         | <b>469</b>    |

**Kết luận ngưỡng:** 0,35 giảm FN so với 0,50 — phù hợp inventory protection; 0,50 tốt hơn nếu ưu tiên F1 / Precision.

#### 3.3 Ma trận nhầm lẫn @ 0,35 (Tuned)

|                           | Dự đoán: Không hủy | Dự đoán: Hủy |
|---------------------------|--------------------|--------------|
| <b>Thực tế: Không hủy</b> | TN = 7.577         | FP = 4.329   |
| <b>Thực tế: Hủy</b>       | FN = 469           | TP = 4.188   |

So RF v1.2: FP giảm từ 6.013 → **4.329** (−28%); FN tăng từ 289 → **469** (+62%) — trade-off rõ khi tăng Precision.

#### 3.4 Phân phối xác suất dự đoán (test — Tuned)

| Nhãn thực tế | n      | Mean P(hủy)  | Median P(hủy) | Std   |
|--------------|--------|--------------|---------------|-------|
| Không hủy    | 11.906 | 0,289        | 0,231         | 0,250 |
| Hủy          | 4.657  | <b>0,691</b> | <b>0,745</b>  | 0,227 |

Hai phân phối tách lớp rõ hơn RF v1.2 (median Không hủy: 0,35 → **0,23**; median Hủy: 0,63 → **0,75**). Mô hình LightGBM calibrated tốt hơn, giảm overlap vùng 0,25–0,55.

## 4. Feature importance (gain)

### 4.1 Top 20 feature (sau tiền xử lý)

| Hạng | Feature                       | Gain          | Biến gốc / nhóm                   |
|------|-------------------------------|---------------|-----------------------------------|
| 1    | lead_time                     | 57.672        | lead_time                         |
| 2    | country_PRT                   | 38.574        | country                           |
| 3    | market_segment_Online TA      | 36.623        | market_segment                    |
| 4    | total_of_special_requests     | 26.969        | total_of_special_requests         |
| 5    | price_per_person              | <b>23.828</b> | <b>Financial Commitment</b>       |
| 6    | lead_time_per_night           | <b>16.923</b> | <b>Trip Structure</b>             |
| 7    | arrival_month_mapped          | <b>12.350</b> | <b>Calendar &amp; Seasonality</b> |
| 8    | history_cancel_rate           | <b>11.634</b> | <b>Trust &amp; History</b>        |
| 9    | customer_type_Transient       | 10.870        | customer_type                     |
| 10   | total_nights                  | <b>10.556</b> | <b>Trip Structure</b>             |
| 11   | deposit_type_Non Refund       | 7.327         | deposit_type                      |
| 12   | total_guests                  | <b>5.584</b>  | <b>Financial Commitment</b>       |
| 13   | distribution_channel_TA/TO    | 5.440         | distribution_channel              |
| 14   | market_segment_Offline TA/TO  | 4.911         | market_segment                    |
| 15   | market_segment_Direct         | 4.671         | market_segment                    |
| 16   | customer_type_Transient-Party | 4.604         | customer_type                     |
| 17   | hotel_City Hotel              | 3.145         | hotel                             |
| 18   | deposit_type_No Deposit       | 2.671         | deposit_type                      |
| 19   | country_GBR                   | 2.536         | country                           |
| 20   | country_DEU                   | 2.341         | country                           |

**Nhận xét:** 5 biến engineered trong top 20; price\_per\_person vượt lead\_time\_per\_night so với RF v1.2.

### 4.2 Gom nhóm theo biến gốc (tổng gain)

| Hạng | Biến / nhóm               | Tổng gain     | Đánh giá                  |
|------|---------------------------|---------------|---------------------------|
| 1    | country                   | 58.645        | Thị trường nguồn (PRT)    |
| 2    | lead_time                 | 57.672        | Đặt trước xa → rủi ro cao |
| 3    | market_segment            | 48.270        | OTA / Direct              |
| 4    | total_of_special_requests | 26.969        | Cam kết / nhu cầu cụ thể  |
| 5    | price_per_person          | <b>23.828</b> | Cam kết tài chính         |


| Hạng | Biến / nhóm          | Tổng gain     | Đánh giá                    |
|------|----------------------|---------------|-----------------------------|
| 6    | customer_type        | 17.171        | Transient rủi ro hơn        |
| 7    | lead_time_per_night  | <b>16.923</b> | <b>Biến engineered mạnh</b> |
| 8    | arrival_month_mapped | <b>12.350</b> | Mùa vụ                      |
| 9    | history_cancel_rate  | <b>11.634</b> | Lịch sử hủy                 |
| 10   | total_nights         | <b>10.556</b> | Cấu trúc chuyến đi          |
| 11   | deposit_type         | 9.998         | Chính sách cọc              |
| 12   | distribution_channel | 8.335         | TA/TO vs Direct             |
| 13   | total_guests         | <b>5.584</b>  | Quy mô nhóm                 |
| 14   | hotel                | 5.058         | City vs Resort              |
| 15   | is_family            | <b>1.432</b>  | Gia đình — yếu              |
| 16   | is_weekend_only      | <b>0.185</b>  | Cuối tuần — yếu nhất        |

## 5. Giải thích SHAP — Biến engineered

### 5.1 Phương pháp

| Thành phần         | Cài đặt                                                             |
|--------------------|---------------------------------------------------------------------|
| Thư viện           | shap — TreeExplainer                                                |
| Mô hình giải thích | LGBMClassifier (tuned) sau ColumnTransformer                        |
| Dữ liệu            | Mẫu <b>2.000</b> booking ngẫu nhiên từ tập test ( random_state=42 ) |
| Class giải thích   | <b>Hủy</b> (class 1)                                                |

### 5.2 Mean |SHAP| — Xếp hạng biến engineered



| Hạng | Biến                 | Mean [SHAP] | Mean SHAP | Nhóm                 | Diễn giải                               |
|------|----------------------|-------------|-----------|----------------------|-----------------------------------------|
| 1    | price_per_person     | 0,244       | -0,012    | Financial Commitment | Đóng góp lớn nhất trong nhóm engineered |
| 2    | lead_time_per_night  | 0,139       | +0,004    | Trip Structure       | Chuẩn hóa lead time theo độ dài chuyến  |
| 3    | arrival_month_mapped | 0,130       | -0,005    | Calendar             | Mùa vụ — SHAP mạnh hơn gain gợi ý       |
| 4    | history_cancel_rate  | 0,121       | +0,012    | Trust & History      | Lịch sử hủy cao → đẩy P(hủy) lên        |
| 5    | total_nights         | 0,117       | +0,010    | Trip Structure       | Số đêm và cấu trúc chuyến               |
| 6    | total_guests         | 0,095       | +0,003    | Financial Commitment | Quy mô nhóm khách                       |
| 7    | is_family            | 0,026       | -0,001    | Financial Commitment | Tác động nhỏ                            |
| 8    | is_weekend_only      | 0,002       | -0,000    | Calendar             | Yếu nhất                                |


**So v1.2 (RF):** LightGBM SHAP nhấn mạnh price\_per\_person (#1 engineered) thay vì lead\_time\_per\_night (#1 ở RF). arrival\_month\_mapped tăng đóng góp SHAP đáng kể so Gini importance thấp.

5.3 Tổng hợp theo nhóm feature engineering



| Nhóm                   | Tổng mean [SHAP] | Mean SHAP | Đánh giá                                                    |
|------------------------|------------------|-----------|-------------------------------------------------------------|
| Financial Commitment   | 0,365            | -0,009    | Nhóm engineered quan trọng nhất — price_per_person chi phối |
| Trip Structure         | 0,255            | +0,014    | lead_time_per_night + total_nights                          |
| Calendar & Seasonality | 0,132            | -0,005    | arrival_month_mapped mạnh hơn is_weekend_only               |
| Trust & History        | 0,121            | +0,012    | history_cancel_rate — tín hiệu có hướng                     |



5.4 SHAP Beeswarm — Phân tán đóng góp theo từng booking



Mỗi chấm là một booking trong mẫu 2.000; trục ngang là giá trị SHAP (đóng góp vào P(hủy)), màu thể hiện giá trị feature (cao → đỏ, thấp → xanh). Beeswarm bổ sung cho bảng 5.2–5.3 bằng cách cho thấy **phân bố** và **hướng** tác động trên từng quan sát — ví dụ `history_cancel_rate` cao tập trung SHAP dương mạnh; `price_per_person` cao thường kéo SHAP âm.



## 6. Trực quan hóa & đánh giá biểu đồ

### 6.1 Confusion Matrix (@ 0,35 — Tuned)





FN = 469, FP = 4.329. Cân bằng tốt hơn RF v1.2 về Precision (ít FP hơn), nhưng FN cao hơn — cần cân nhắc hạ ngưỡng xuống 0,30 nếu ưu tiên Recall tuyệt đối.

### 6.2 ROC Curve (AUC = 0,871)




Cải thiện rõ so RF v1.2 (0,840) và baseline LGBM (0,867). Mô hình xếp hạng rủi ro tốt; phù hợp scoring / prioritization.

### 6.3 Prediction Probability Distribution



Median P(hủy): Không hủy **0,23** · Hủy **0,75** — tách lớp tốt hơn v1.2. Ngưỡng 0,35 nằm trên median class Không hủy → vẫn đảm bảo Recall cao.

### 6.4 Gain importance vs SHAP



| Góc nhìn                | Gain (LightGBM)                                              | SHAP                               |
|-------------------------|--------------------------------------------------------------|------------------------------------|
| Phạm vi                 | Toàn cục, split quality                                      | Local + trung bình có dấu          |
| Biến engineered nổi bật | lead_time_per_night , price_per_person , history_cancel_rate | price_per_person #1 engineered     |
| Khuyến nghị             | Ranking feature, monitoring drift                            | Giải thích quyết định từng booking |

## 7. Kết luận tổng thể

### Điểm mạnh v2

- ROC-AUC 0,871** — tốt nhất trong các phiên bản (v1.1: 0,831 · v1.2: 0,840 · v2: **0,871**).
- Tình hình Optuna** cải thiện +0,005 AUC so baseline LGBM với cùng feature.
- Precision Hủy 0,49 @ 0,35** — cao hơn RF v1.2 (~42%), giảm cảnh báo sai.
- Feature engineering v1.2** vẫn có giá trị; 5/8 biến engineered trong top 20 gain.
- SHAP** xác nhận `price_per_person` và `history_cancel_rate` là trụ chính ngoài `lead_time` / segment.

### Hạn chế & rủi ro

1. **Recall Hủy 0,90** thấp hơn RF v1.2 (0,94) @ cùng ngưỡng 0,35 — FN = 469 vs 289.
2. Tune theo `roc_auc` không tối ưu trực tiếp Recall — cần quét ngưỡng hoặc `scale_pos_weight` nếu mục tiêu là không bỏ sót hủy.
3. GridSearch + Optuna **tốn thời gian** (~5–10 phút) — production nên lưu `best_params` cố định.
4. SHAP / gain **không phải nhân quả** — cần A/B trước khi đổi chính sách.

## Khuyến nghị hành động

| Ưu tiên | Hành động                                                                                              | Ghi chú                  |
|---------|--------------------------------------------------------------------------------------------------------|--------------------------|
| 1       | Triển khai pilot scoring với <b>LightGBM tuned</b> + ngưỡng 0,35                                       | AUC 0,871, Precision cao |
| 2       | Nếu cần Recall $\geq 0,94$ : thử ngưỡng <b>0,28–0,30</b> hoặc tăng <code>scale_pos_weight</code>       | Trade-off Precision      |
| 3       | Rule: <code>history_cancel_rate</code> > 0 + <b>Online TA</b> → xác nhận chặt                          | SHAP + gain              |
| 4       | Rule: <code>price_per_person</code> <b>thấp</b> + lead time dài → ưu tiên cọc                          | Financial Commitment     |
| 5       | Lưu <code>best_params</code> Optuna vào artifact production; tắt <code>RUN_TUNING</code> khi inference | Notebook mục 3b          |

## 8. Tài liệu liên quan

| Tài liệu                                                                         | Nội dung                      |
|----------------------------------------------------------------------------------|-------------------------------|
| <code>models/Cancellation Predict Model v2/09_cancellation_model_v2.ipynb</code> | Notebook đầy đủ (tune + SHAP) |
| <a href="#">08_cancellation_model_v1_2.md</a>                                    | RF v1.2 — cùng feature set    |
| <a href="#">07_cancellation_model_v1_1.md</a>                                    | Phiên bản 9 feature           |
| <a href="#">06_cancellation_model_v1.md</a>                                      | Baseline phân loại            |
| <a href="#">04_correlation_analysis_is_canceled.md</a>                           | Tier feature & leakage        |