

Báo cáo mô hình dự đoán hủy phòng — LightGBM v2

Nguồn dữ liệu: hotel_bookings_v5.csv

Phạm vi: 82.811 booking | Tỷ lệ hủy tăng trưởng: 28,12% (~23.284 booking bị hủy)

Notebook tham chiếu: models/Cancellation Predict Model v2/09_cancellation_model_v2.ipynb

Thuật toán: LGBMClassifier (LightGBM) + tìm kiếm GridSearchCV & Optuna + giải thích SHAP (TreeExplainer)

Ngưỡng phân loại: 0,35 ($P(hủy) \geq 0,35 \rightarrow$ dự đoán Hủy)

1. Mục tiêu & khác biệt so với RF v1.2

v2 kế thừa toàn bộ feature engineering từ v1.2 (16 biến, 4 nhóm engineered), thay thuật toán Random Forest bằng LightGBM và bổ sung tìm kiếm hyperparameter tối ưu.

Tiêu chí	RF v1.2	LightGBM v2
Thuật toán	RandomForestClassifier	LGBMClassifier
Số feature	16 (6 phân loại + 10 số)	Giữ nguyên v1.2
Feature engineering	9 biến engineered (4 nhóm)	Giữ nguyên
Tìm kiếm HP	Không (cố định)	GridSearchCV + Optuna (mức 3b)
Importance	Gini	Gain (chuẩn GBDT)
Ngưỡng	0,35	0,35 (so sánh công bằng)
ROC-AUC (test)	0,840	0,871 (tuned)
Recall — Hủy @ 0,35	0,94	0,90
Precision — Hủy @ 0,35	0,42	0,49
Accuracy @ 0,35	0,62	0,71

Cải thiện chính: ROC-AUC tăng +0,031 (~+3,7%) so RF v1.2; Precision Hủy tăng ~7 điểm phần trăm. Recall Hủy giảm nhẹ (0,90 vs 0,94) do trade-off khi mô hình calibrated tốt hơn — có thể bù bằng hệ thống ưu tiên inventory protection.

2. Thiết kế mô hình

2.1 Feature engineering (4 nhóm — giữ nguyên v1.2)

Nhóm 1 — Mục cam kết tài chính (Financial Commitment)

Biến	Công thức	Ghi chú
total_guests	adults + children + babies	Clip tối thiểu = 1
price_per_person	adr / total_guests	Giá trên mỗi khách
is_family	1 nếu children > 0 hoặc babies > 0	Nhóm gia đình

Nhóm 2 — Cấu trúc chuyến đi (Trip Structure)

Biến	Công thức	Ghi chú
total_nights	stays_in_weekend_nights + stays_in_week_nights	Tổng đêm lưu trú
lead_time_per_night	lead_time / total_nights	Clip tối thiểu ≥ 1

Nhóm 3 — Lịch sử và uy tín (Trust & History)

Biến	Công thức	Ghi chú
history_cancel_rate	previous_cancellations / (previous_cancellations + previous_bookings_not_canceled)	= 0 nếu khách có lịch sử

Nhóm 4 — Lịch & mùa (Calendar & Seasonality)

Biến	Công thức	Ghi chú
is_weekend_only	1 nếu weekend_nights > 0 và week_nights == 0	Chỉ lưu trú cuối tuần
arrival_month_mapped	Tháng gốc → số 1-12 (Jan→1 ... Dec→12)	Mùa vụ

2.2 Feature đưa vào mô hình (16 biến)

Biến	Kiểu	Xử lý
deposit_type, market_segment, country, distribution_channel, customer_type, hotel	Phân loại	One-Hot Encoding
lead_time, total_of_special_requests	Số (v1.1)	Passthrough
8 biến engineered trên	Số	Passthrough

ColumnTransformer: nhánh cat (One-Hot, min_frequency=5) + nhánh num (passthrough). Sau encoding: 139 cột đưa vào LightGBM.

2.3 Hyperparameter

Baseline (trước tune)

Tham số	Giá trị
n_estimators	300
max_depth	12
min_child_samples	20
learning_rate	0,05
subsample	0,8
colsample_bytree	0,8
class_weight	balanced

Tính chính xác (mục 3b notebook)

Phương pháp	Metric tiêu	CV ROC-AUC
Baseline	—	0,862
GridSearchCV (64 tập hợp, 3-fold)	roc_auc	0,863
Optuna TPE (35 trials, 3-fold)	roc_auc	0,865

Chọn: Optuna (CV ROC-AUC cao hơn GridSearch).

Best params (Optuna — mô hình production trong notebook)

Tham số	Giá trị
n_estimators	250
max_depth	15
num_leaves	61
min_child_samples	35
learning_rate	0,063
subsample	0,796

colsample_bytree	0,633
reg_alpha	0,008
reg_lambda	3,265
class_weight	balanced

2.4 Chẩn data leakage

1. Không nập reservation_status, revenue, Occupancy_Rate, RevPAR, ...
2. Feature engineering chỉ dùng thông tin có tại thời điểm đặt phòng.
3. train_test_split trước khi build fit encoder và tune.
4. OneHotEncoder + GridSearch/Optuna chỉ fit trên tập train (qua Pipeline).

2.5 Ngưỡng 0,35

y_pred = 1 nếu P(hay) >= 0.35

Giống v1.2 so sánh công bằng: ưu tiên Recall, chấp nhận tăng False Positive.

3. Kết quả đánh giá (tập test — 16.563 booking)

3.1 So sánh Baseline vs Tuned @ ngưỡng 0,35

Chỉ số	Baseline LGBM	Tuned (Optuna)	RF v1.2 (tham chiếu)
ROC-AUC (test)	0,867	0,871	0,840
CV ROC-AUC (5-fold)	—	0,867 ± 0,004	0,838 ± 0,004
Accuracy	0,698	0,710	0,62
Precision — Hay	0,480	0,492	0,42
Recall — Hay	0,905	0,899	0,94
F1 — Hay	0,627	0,636	0,58
Precision — Không hay	0,94	0,94	0,95
Recall — Không hay	0,64	0,64	0,49

Nhận xét: Tuned cải thiện AUC (+0,005), Accuracy, Precision và F1; Recall giảm nhẹ (−0,6 điểm phần trăm) so baseline LGBM. So RF v1.2: AUC cao hơn rõ, Precision tốt hơn, Recall thấp hơn ~4 điểm phần trăm.

3.2 So sánh ngưỡng 0,35 vs 0,50 (mô hình Tuned)

Metric (class H _h y)	@ 0,50	@ 0,35
F1	0,676	0,636
Recall	~0,79	0,90
FN (b _h sốt h _h y)	~980	469

K_ht lu_hn ng_hng: 0,35 gi_hm FN so v_hi 0,50 — phù h_hp inventory protection; 0,50 t_ht h_hn n_hu _hu tiên F1 / Precision.

3.3 Ma tr_hn nh_hm l_hn @ 0,35 (Tuned)

	D _h _h oán: Không h _h y	D _h _h oán: H _h y
Th _h c t _h : Không h _h y	TN = 7.577	FP = 4.329
Th _h c t _h : H _h y	FN = 469	TP = 4.188

So RF v1.2: FP gi_hm t_h 6.013 → 4.329 (−28%); FN t_hng t_h 289 → 469 (+62%) — trade-off rõ khi t_hng Precision.

3.4 Phân ph_hi xác su_ht d_h _hoán (test — Tuned)

Nh _h n th _h c t _h	n	Mean P(h _h y)	Median P(h _h y)	Std
Không h _h y	11.906	0,289	0,231	0,250
H _h y	4.657	0,691	0,745	0,227

Hai phân ph_hi tách l_hp rõ h_hn RF v1.2 (median Không h_hy: 0,35 → 0,23; median H_hy: 0,63 → 0,75). Mô hình LightGBM calibrated t_ht h_hn, gi_hm overlap vùng 0,25–0,55.

4. Feature importance (gain)

4.1 Top 20 feature (sau ti_hn x_h lý)

H _h ng	Feature	Gain	Bi _h n g _h c / nhóm
1	lead_time	57.672	lead_time
2	country_PRT	38.574	country

3	market_segment_Online TA	36.623	market_segment
4	total_of_special_requests	26.969	total_of_special_requests
5	price_per_person	23.828	Financial Commitment
6	lead_time_per_night	16.923	Trip Structure
7	arrival_month_mapped	12.350	Calendar & Seasonality
8	history_cancel_rate	11.634	Trust & History
9	customer_type_Transient	10.870	customer_type
10	total_nights	10.556	Trip Structure
11	deposit_type_Non Refund	7.327	deposit_type
12	total_guests	5.584	Financial Commitment
13	distribution_channel_TA/TO	5.440	distribution_channel
14	market_segment_Offline TA/TO	4.911	market_segment
15	market_segment_Direct	4.671	market_segment
16	customer_type_Transient-Party	4.604	customer_type
17	hotel_City Hotel	3.145	hotel
18	deposit_type_No Deposit	2.671	deposit_type
19	country_GBR	2.536	country
20	country_DEU	2.341	country

Nhấn xét: 5 biến engineered trong top 20; price_per_person vượt lead_time_per_night so với RF v1.2.

4.2 Gom nhóm theo biến gốc (tăng gain)

Hạng	Biến / nhóm	Tăng gain	Đánh giá
1	country	58.645	Thì trình ngu (PRT)
2	lead_time	57.672	Trình xa → rí ro cao


3	market_segment	48.270	OTA / Direct
4	total_of_special_requests	26.969	Cam kết / nhu cầu cụ thể
5	price_per_person	23.828	Cam kết tài chính
6	customer_type	17.171	Transient rời rạc
7	lead_time_per_night	16.923	Biến engineered mới
8	arrival_month_mapped	12.350	Mùa vụ
9	history_cancel_rate	11.634	Lịch sử hủy
10	total_nights	10.556	Cấu trúc chuyến đi
11	deposit_type	9.998	Chính sách cọc
12	distribution_channel	8.335	TA/TO vs Direct
13	total_guests	5.584	Quy mô nhóm
14	hotel	5.058	City vs Resort
15	is_family	1.432	Gia đình — yêu
16	is_weekend_only	0.185	Cuối tuần — yêu nhất

5. Giải thích SHAP — Biến engineered

5.1 Phương pháp

Thành phần	Cài đặt
Thư viện	shap — TreeExplainer
Mô hình giải thích	LGBMClassifier (tuned) sau ColumnTransformer
Dữ liệu	Mẫu 2.000 booking ngẫu nhiên tập test (random_state=42)
Class giải thích	Hủy (class 1)


5.2 Mean |SHAP| — Tập hợp biến engineered



Hàng	Biến	Mean SHAP	Mean SHAP	Nhóm	Diễn giải
1	price_per_person	0,244	-0,012	Financial Commitment	Đóng góp lớn nhất trong nhóm engineered
2	lead_time_per_night	0,139	+0,004	Trip Structure	Chuẩn hóa lead time theo độ dài chuyến
3	arrival_month_mapped	0,130	-0,005	Calendar	Mùa vụ — SHAP minh họa gain giá ý
4	history_cancel_rate	0,121	+0,012	Trust & History	Lịch sử hủy cao → Tỷ lệ P(hủy) lên
5	total_nights	0,117	+0,010	Trip Structure	Số đêm và cấu trúc chuyến
6	total_guests	0,095	+0,003	Financial Commitment	Quy mô nhóm khách
7	is_family	0,026	-0,001	Financial Commitment	Tác động nhỏ
8	is_weekend_only	0,002	-0,000	Calendar	Yếu nhất


So v1.2 (RF): LightGBM SHAP nhận thấy `price_per_person` (#1 engineered) thay vì `lead_time_per_night` (#1 RF). `arrival_month_mapped` tăng đóng góp SHAP đáng kể so Gini importance thấp.

5.3 Tổng hợp theo nhóm feature engineering



Nhóm	Tổng mean SHAP	Mean SHAP	Đánh giá
Financial Commitment	0,365	-0,009	Nhóm engineered quan trọng nhất — price_per_person chi phí
Trip Structure	0,255	+0,014	lead_time_per_night + total_nights
Calendar & Seasonality	0,132	-0,005	arrival_month_mapped mạnh hơn is_weekend_only
Trust & History	0,121	+0,012	history_cancel_rate — tín hiệu có hướng



5.4 SHAP Beeswarm — Phân tán đóng góp theo từng booking



Mũi chĩa là mũi booking trong mẫu 2.000; trục ngang là giá trị SHAP (đóng góp vào $P(h|y)$), màu thể hiện giá trị feature (cao → đỏ, thấp → xanh). Beeswarm bổ sung cho bảng 5.2–5.3 bằng cách cho thấy phân bố và hướng tác động trên từng quan sát — ví dụ `history_cancel_rate` cao tập trung SHAP dương mạnh; `price_per_person` cao thường kéo SHAP âm.


6. Trắc quan hóa & đánh giá biểu đồ

6.1 Confusion Matrix (@ 0,35 — Tuned)




FN = 469, FP = 4.329. Cân bằng tốt hơn RF v1.2 về Precision (ít FP hơn), nhưng FN cao hơn — cần cân nhắc hướng xu hướng 0,30 ưu tiên Recall tùy bài.

6.2 ROC Curve (AUC = 0,871)




Cái thì rõ so RF v1.2 (0,840) và baseline LGBM (0,867). Mô hình xấp xỉ rủi ro tốt; phù hợp scoring / prioritization.

6.3 Prediction Probability Distribution



Median P(hủy): Không hủy 0,23 · Hủy 0,75 — tách lớp tốt hơn v1.2. Ngưỡng 0,35 nằm trên median class Không hủy → vẫn đảm bảo Recall cao.

6.4 Gain importance vs SHAP



Góc nhìn	Gain (LightGBM)	SHAP
Phạm vi	Toàn cục, split quality	Local + trung bình có dữ liệu
Biến engineered nào tốt	lead_time_per_night, price_per_person, history_cancel_rate	price_per_person #1 engineered
Khuyến nghị	Ranking feature, monitoring drift	Giới thích quy tắc hành động booking

7. Kết luận tổng thể

Mức minh v2

- ROC-AUC 0,871 — tốt nhất trong các phiên bản (v1.1: 0,831 · v1.2: 0,840 · v2: 0,871).
- Tính chính xác Optuna cải thiện +0,005 AUC so baseline LGBM với cùng feature.
- Precision Hủy 0,49 @ 0,35 — cao hơn RF v1.2 (~42%), giảm chênh lệch sai.
- Feature engineering v1.2 vẫn có giá trị; 5/8 biến engineered trong top 20 gain.
- SHAP xác nhận price_per_person và history_cancel_rate là trọng yếu ngoài lead_time / segment.

Hạn chế & rủi ro

- 1. Recall Hủy 0,90 thấp hơn RF v1.2 (0,94) @ cùng ngưỡng 0,35 — FN = 469 vs 289.
- 2. Tune theo roc_auc không tối ưu trực tiếp Recall — cần quét ngưỡng hoặc scale_pos_weight nếu mục tiêu là không bỏ sót hủy.
- 3. GridSearch + Optuna tốn thời gian (~5–10 phút) — production nên lưu best_params cục bộ.
- 4. SHAP / gain không phải nhân quả — cần A/B trực tiếp khi đổi chính sách.

Khuyến nghị hành động

Mục tiêu	Hành động	Ghi chú
1	Triển khai pilot scoring với LightGBM tuned + ngưỡng 0,35	AUC 0,871, Precision cao
2	Nếu cần Recall ≥ 0,94: thử ngưỡng 0,28–0,30 hoặc tuning scale_pos_weight	Trade-off Precision
3	Rule: history_cancel_rate > 0 + Online TA → xác nhận chốt	SHAP + gain
4	Rule: price_per_person thấp + lead time dài → ưu tiên cắt	Financial Commitment
5	Lưu best_params Optuna vào artifact production; tắt RUN_TUNING khi inference	Notebook mục 3b

8. Tài liệu liên quan

Tài liệu	Nội dung
models/Cancellation Predict Model v2/09_cancellation_model_v2.ipynb	Notebook hủy (tune + SHAP)
08_cancellation_model_v1_2.md	RF v1.2 — cùng feature set
07_cancellation_model_v1_1.md	Phiên bản 9 feature
06_cancellation_model_v1.md	Baseline phân loại
04_correlation_analysis_is_canceled.md	Tier feature & leakage