

Cancellation Prediction Model — Random Forest

v1.1

Nguồn dữ liệu: hotel_bookings_v5.csv

Phạm vi: 82.811 booking | Tỷ lệ hủy tổng thể: **28,12%** (~23.284 booking bị hủy)

Notebook tham chiếu: Cancellation_Prediction_Model_v1_1.ipynb

Thuật toán: RandomForestClassifier (scikit-learn)

Ngưỡng phân loại: **0,35** ($P(\text{hủy}) \geq 0,35 \rightarrow \text{dự đoán Hủy}$)

1. Mục tiêu & khác biệt so với v1

v1.1 mở rộng baseline v1 bằng:

- 3 biến số:** lead_time, total_of_special_requests, previous_cancellations
- Ngưỡng 0,35** thay vì 0,50 — hạ ngưỡng để tăng độ nhạy bắt booking có nguy cơ hủy

Tiêu chí	v1	v1.1
Số feature	6 (phân loại)	9 (6 phân loại + 3 số)
Ngưỡng	0,50	0,35
ROC-AUC (test)	0,734	0,831
Recall — Hủy @ ngưỡng chính	0,85 @ 0,50	0,94 @ 0,35

2. Thiết kế mô hình

2.1 Feature (9 biến)

Biến	Kiểu	Xử lý
deposit_type, market_segment, country, distribution_channel, customer_type, hotel	Phân loại	One-Hot Encoding
lead_time	Số nguyên	Passthrough
total_of_special_requests	Số nguyên	Passthrough
previous_cancellations	Số nguyên	Passthrough

ColumnTransformer: nhánh cat (One-Hot, min_frequency=5) + nhánh num (passthrough). Random Forest không cần chuẩn hóa scale.

2.2 Chống data leakage

Giữ nguyên nguyên tắc v1: không nạp reservation_status, revenue, Occupancy_Rate, RevPAR; split trước fit encoder; category hiếm học từ train.

Lưu ý diễn giải: previous_cancellations là lịch sử khách (có tại thời điểm đặt), không phải leakage của booking hiện tại. lead_time và total_of_special_requests đều biết khi đặt phòng.

2.3 Ngưỡng 0,35

```
y_pred = 1 nếu P(hủy) >= 0.35
```

Ý nghĩa kinh doanh: Chấp nhận gắn nhãn “có nguy cơ hủy” sớm hơn → **tăng Recall**, giảm FN (bỏ sót booking sẽ hủy), đổi lại **tăng FP** so với ngưỡng cao hơn.

3. Kết quả đánh giá (tập test — 16.563 booking)

3.1 Chỉ số tổng hợp @ ngưỡng 0,35

Chỉ số	Giá trị	Diễn giải
ROC-AUC (test)	0,831	Tốt — cải thiện $\sim +0,10$ so với v1
CV ROC-AUC (5-fold)	0,8294 $\pm$ 0,0036	Ổn định, generalize tốt
Accuracy	0,60	Vẫn thấp do class lệch; không dùng làm metric chính
Precision — Hủy	0,41	$\sim 41\%$ dự đoán hủy là đúng
Recall — Hủy	0,94	Bắt $\sim 94\%$ booking thực sự hủy
F1 — Hủy	0,57	Cân bằng P/R cho class thiểu số còn trung bình
Precision — Không hủy	0,95	Rất cao khi dự đoán không hủy
Recall — Không hủy	0,47	$\sim 53\%$ booking không hủy bị gán nhầm “hủy”

3.2 So sánh ngưỡng 0,35 vs 0,50 (cùng mô hình v1.1)

Metric (class Hủy)	@ 0,50	@ 0,35
F1	0,600	0,570
Recall (từ CM)	0,82	0,94
FN (bỏ sót hủy)	~ 822	~ 273

Kết luận ngưỡng: 0,35 không tối ưu F1 nhưng giảm mạnh FN (273 vs 822) — phù hợp chiến lược **ưu tiên không bỏ sót hủy** (overbooking / inventory protection). Nếu cần cân bằng P/R, cân nhắc 0,45–0,50.

3.3 Ma trận nhầm lẫn @ 0,35

	Dự đoán: Không hủy	Dự đoán: Hủy
Thực tế: Không hủy	TN = 5.552	FP = 6.354
Thực tế: Hủy	FN = 273	TP = 4.384

4. Feature importance analysis

4.1 Top 20 feature (sau tiền xử lý)

Hạng	Feature	Importance	Biến gốc
1	lead_time	0,211	lead_time
2	market_segment_Online TA	0,132	market_segment
3	country_PRT	0,110	country
4	total_of_special_requests	0,100	total_of_special_requests
5	market_segment_Offline TA/TO	0,073	market_segment
6	customer_type_Transient	0,046	customer_type
7	distribution_channel_TA/TO	0,045	distribution_channel
8	customer_type_Transient-Party	0,032	customer_type

Hạng	Feature	Importance	Biến gốc
9	previous_cancellations	0,030	previous_cancellations
10	deposit_type_No Deposit	0,028	deposit_type

Nhận xét: lead_time vươn lên #1 sau khi bổ sung biến số — khớp hypothesis (Mann-Whitney, $r \approx 0,30$). total_of_special_requests top 4 (nhiều yêu cầu → ít hủy). previous_cancellations có vai trò nhỏ hơn nhưng vẫn vào top 10.

4.2 Gom nhóm theo biến gốc (tổng Gini importance)

Hạng	Biến gốc	Tổng importance	% trong tổng	Đánh giá
1	`market_segment`	0,248	24,8%	Vấn quan trọng nhất trong nhóm phân loại
2	`lead_time`	0,211	21,1%	Lever hành vi mạnh nhất — đặt trước xa → rủi ro cao
3	`country`	0,175	17,5%	Thị trường nguồn (PRT nổi bật)
4	`total_of_special_requests`	0,100	10,0%	Cam kết / nhu cầu cụ thể → giảm rủi ro
5	`customer_type`	0,088	8,8%	Transient rủi ro hơn Contract/Group
6	`distribution_channel`	0,076	7,6%	OTA (TA/TO) vs Direct
7	`deposit_type`	0,055	5,5%	Non Refund cực kỳ đặc thù (xem segment)
8	`previous_cancellations`	0,030	3,0%	Lịch sử hủy — tín hiệu phụ

Hạng	Biến gốc	Tổng importance	% trong tổng	Đánh giá
9	`hotel`	0,018	1,8%	City Hotel hủy cao hơn Resort

So với v1: `lead_time` chiếm ~21% importance (trước đó không có); `market_segment` giảm tỷ trọng tương đối nhưng vẫn #1; `country` vẫn top 3.

5. Segment cancellation rate

Tỷ lệ hủy **thực tế** (`is_canceled`) theo từng nhóm — đối chiếu với feature importance và hỗ trợ hành động revenue management.

5.1 `lead_time` (ngày đặt trước đến)

Nhóm	Số booking	Tỷ lệ hủy
0–30 ngày	33.039	16,8%
31–60	12.776	32,2%
61–90	8.967	33,2%
91–180	17.355	36,0%
> 180	10.674	41,7%

Đánh giá: Gradient rõ — lead time dài gấp ~2,5 lần rủi ro so với đặt trong 30 ngày. Khớp importance #2 của mô hình.

5.2 market_segment

Segment	n	Tỷ lệ hủy
Online TA	50.391	35,5%
Groups	3.690	31,2%
Offline TA/TO	12.860	15,1%
Direct	11.351	14,9%
Corporate	3.678	12,8%
Complementary	619	13,1%

Đánh giá: Online TA là **nguồn rủi ro chính** (~36% trên mức TB 28%). Corporate/Direct ổn định hơn — phù hợp chính sách cọc/confirmation khác nhau theo segment.

5.3 distribution_channel

Kênh	n	Tỷ lệ hủy
TA/TO	65.956	31,5%
GDS	172	19,8%
Direct	12.291	15,1%
Corporate	4.387	13,6%

5.4 customer_type

Loại khách	n	Tỷ lệ hủy
Transient	69.939	30,4%
Transient-Party	9.294	15,8%
Contract	3.068	16,5%
Group	510	10,6%

5.5 hotel

Khách sạn	n	Tỷ lệ hủy
City Hotel	50.686	30,7%
Resort Hotel	32.125	24,1%

5.6 deposit_type

Loại cọc	n	Tỷ lệ hủy
No Deposit	81.767	27,3%
Non Refund	963	95,0%
Refundable	81	28,4%

Cảnh báo: Non Refund ~95% hủy — có thể phản ánh **chính sách đặc biệt** / **gán nhãn** hơn là hành vi khách điển hình; cần thận trọng khi diễn giải nhân quả.

5.7 total_of_special_requests

Số yêu cầu đặc biệt	n	Tỷ lệ hủy
0	40.983	34,3%
1	27.860	22,9%
2	11.384	21,4%
3+	2.584	16,4%

Đánh giá: Càng nhiều special request → càng cam kết → hủy giảm. Hỗ trợ khuyến khích upsell / personalization có thể giảm rủi ro.

5.8 previous_cancellations

Lịch sử hủy trước	n	Tỷ lệ hủy
0	81.255	27,4%
1	1.303	76,4%
2+	253	22,9%

Đánh giá: Khách từng hủy đúng 1 lần có tỷ lệ hủy rất cao; nhóm 2+ sample nhỏ (253) — không ổn định thống kê.


5.9 country (top 10 theo volume)

Quốc gia	n	Tỷ lệ hủy
PRT	25.299	36,8%
BRA	1.936	36,8%
ITA	2.900	36,1%
ESP	6.973	26,2%
GBR	9.921	19,6%
FRA	8.464	20,1%

Đánh giá: PRT (Bồ Đào Nha) — thị trường nội địa lớn nhất — hủy cao hơn TB; GBR/FRA tương đối ổn định.


6. Trực quan hóa & đánh giá biểu đồ

6.1 Confusion Matrix (@ 0,35)



- **Đánh giá:** Cho thấy chiến lược ngưỡng thấp — FN chỉ 273 nhưng FP 6.354. Phù hợp mục tiêu “bắt hầu hết booking sẽ hủy”, không phù hợp nếu mỗi cảnh báo đều tốn chi phí can thiệp.



6.2 ROC Curve (AUC = 0,8305 ~0,831)



- **Đánh giá:** Cải thiện rõ so với v1 (0,734). Mô hình **xếp hạng rủi ro tốt**; ngưỡng 0,35 là điểm cắt trên đường ROC, không làm thay đổi AUC.
- **Gợi ý:** Kết hợp ROC với **Precision-Recall curve** nếu cần tối ưu ngưỡng theo chi phí FP/FN.

6.3 Prediction Probability Distribution (Histogram + KDE)


- **Quy ước màu:** teal = Không hủy · orange = Hủy · đường đứt nét = **ngưỡng 0,35**.



- **Đánh giá:** Hai phân phối **tách lớp tốt hơn v1** (AUC cao hơn). Vẫn có overlap vùng 0,25–0,55 — bình thường với dữ liệu hành vi. Median **P (hủy)** nhóm thực sự hủy cao hơn nhóm không hủy (xem notebook).
- **Ngưỡng 0,35:** Nằm trong vùng overlap → tăng Recall nhưng kéo theo nhiều FP từ phân phối “Không hủy”.

6.4 Feature Importance (bar chart top 20 + bảng gom nhóm)

- **Đánh giá:** Xác nhận **lead_time** và **market_segment** là hai trục chính; hỗ trợ ưu tiên can thiệp (chính sách lead time, OTA segment, incentive special requests).



7. Kết luận tổng thể

Điểm mạnh v1.1

1. **ROC-AUC 0,831** — mức **tốt**, sẵn sàng cho giai đoạn pilot / scoring nội bộ.
2. Bổ sung biến số giúp mô hình **giải thích được** và khớp EDA (lead time, special requests).
3. Ngưỡng **0,35** phù hợp bài toán **giảm bỏ sót hủy** (Recall 94%).
4. Segment analysis chỉ ra **Online TA, City Hotel, PRT, lead time > 180 ngày** là nhóm ưu tiên can thiệp.

Hạn chế & rủi ro

1. **Precision thấp** (~41%) @ 0,35 — nhiều booking không hủy bị flag.
2. `deposit_type_Non Refund` và segment cực nhỏ (Undefined, 2+ cancellations) — dễ nhiễu.
3. Random Forest importance **không phải causal** — cần đối chiếu A/B hoặc chính sách trước khi triển khai.
4. Chưa tune hyperparameter / chưa calibration xác suất (Platt / isotonic).

Khuyến nghị hành động

Ưu tiên	Hành động	Segment / feature liên quan
1	Chính sách cọc / xác nhận chặt hơn cho Online TA + lead time > 90 ngày	<code>market_segment</code> , <code>lead_time</code>
2	Theo dõi riêng khách PRT và previous_cancellations = 1	<code>country</code> , lịch sử
3	Khuyến khích special requests / bundle dịch vụ	<code>total_of_special_requests</code>
4	Pilot scoring: <code>P(hủy) >= 0,35</code> → alert RM; đo FP cost thực tế	Ngưỡng v1.1

8. Tài liệu liên quan

Tài liệu	Nội dung
<code>Cancellation_Prediction_Model_v1_1.ipynb</code>	Notebook đầy đủ
Cancellation Prediction Model v1.md	Baseline phân loại

Tài liệu	Nội dung
Hypothesis Testing - is_canceled.md	Kiểm định lead_time, deposit, segment
Correlation Analysis - is_canceled.md	Tier feature & leakage